HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN 1

PROJECT 01

HỆ ĐA AGENT CHO BỆNH TIỂU ĐƯỜNG

PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH

Giảng viên:	PGS. TS. Trần Đình Quế
Sinh viên:	Kiều Trường Giang
Mã sinh viên:	B23DCCN254
Nhóm học phần:	06
Nhóm thực hiện:	02

Hà Nội, tháng 11 năm 2026

Mục lục

1. Giới thiệu 1

1.1. Bài toán và sản phẩm 1

1.2. Phạm vi đầu ra 1

1.3. Mục tiêu đánh giá 1

2. Agent và cơ chế phối hợp 2

2.1. Vai trò xử lý 2

2.2. Reinforcement Learning kết hợp luật 2

2.3. Giới hạn của kiến trúc 3

3. Kiến trúc tổng quan 4

3.1. Nhánh dữ liệu 4

3.2. Nhánh tri thức 4

3.3. Luồng người dùng 5

4. Nguồn dữ liệu và quy trình chuẩn bị 6

4.1. Phân biệt dữ liệu mô hình với tài liệu tri thức 6

4.2. Nguồn và phiên bản bộ phân loại 6

4.3. Từ điển đầu vào và giá trị thiếu 7

4.4. Phép chia và dấu vết tái lập 8

4.5. Nguồn bộ hồi quy và ý nghĩa mục tiêu 8

4.6. Nguồn KB và nguồn đang thực sự được dùng 9

4.7. Từ nguồn tới kết quả hiển thị 10

5. Các thành phần và thực nghiệm 11

5.1. Phân loại 11

5.2. Hồi quy 11

5.3. Kết quả kiểm tra 11

5.4. Truy xuất và đồ thị 12

5.5. Phân tích sai số theo lớp 12

5.6. Phân tích phần dư hồi quy 13

5.7. Hợp đồng dữ liệu và API 14
5.8. Kết quả kiểm thử tích hợp 14
5.9. Đối chiếu với sơ đồ yêu cầu 14

6. Code và demo 16
6.1. Địa chỉ và cách chạy 16
6.2. Kịch bản trình diễn 16
6.3. Hạn chế và hướng hoàn thiện 17
6.4. Triển khai công khai trên Vercel và Neo4j Aura 17
6.4.1. Kiến trúc triển khai 17
6.4.2. Nạp dữ liệu và kiểm tra 18
6.4.3. Vận hành trong gói miễn phí 18

7. Tinh chỉnh mô hình hội thoại trên máy cá nhân 19
7.1. Mục tiêu và phạm vi 19
7.2. Dữ liệu và thiết kế đánh giá 19
7.2.1. Nguồn và cách xây dựng 19
7.2.2. Đối chiếu trước và sau tinh chỉnh 19
7.3. Cấu hình và quá trình học 20
7.3.1. Kết quả đo trên máy thực nghiệm 20
7.3.2. Phân tích phản hồi và giới hạn 21
7.4. Phối hợp đa agent khi trả lời 21
7.5. Tái lập và vận hành 22
7.5.1. Kiểm thử tích hợp trên web local 23

8. Giao diện và kịch bản sử dụng 25
8.1. Thiết kế giao diện và cách đọc kết quả 25
8.1.1. Trợ lý kiến thức 25
8.1.2. Thực nghiệm dữ liệu: phân loại 26
8.1.3. Thực nghiệm dữ liệu: hồi quy 27
8.1.4. Đồ thị tri thức và đối chiếu Neo4j 28
8.1.5. Dữ liệu và nguồn 30
8.2. Thiết kế và vận hành chatbot tiểu đường 31
8.2.1. Ngữ cảnh, phạm vi và cơ chế trả lời 31
8.2.2. Kiểm tra chỉ số trước khi giải thích 32

8.2.3. Nối mô hình với hội thoại và so sánh đầu vào 32
8.2.4. Tra cứu KB và sử dụng Neo4j 33
8.2.5. Kiểm thử bổ sung và thiết bị 33
8.2.6. Hội thoại tiếp nối và đối chiếu nhiều chỉ số 35

A. Mã nguồn tái lập 37
A.1. scripts/ingest_graph.py 37
A.2. scripts/train_models.py 37
A.3. scripts/train_policy.py 38
A.4. app/agents.py 39
A.5. app/conversation.py 39
A.6. app/main.py 44
A.7. scripts/test_scenarios.py 47
A.8. scripts/test_chatbot.py 47

Danh mục hình

3.1. Hai nhánh hội tụ về điều phối và trợ giúp, dựng lại từ sơ đồ trên bảng. 4

5.1. Ma trận nhầm lẫn của MLP trên tập kiểm tra phân tầng. 13
5.2. Dự đoán và phần dư của MLP trên 89 mẫu kiểm tra. 13

7.1. Loss huấn luyện theo bước và validation theo epoch. Điểm đầu validation thuộc mô hình nền. 20
7.2. Luồng xử lý tại máy cá nhân; phản hồi không đạt kiểm tra quay về nội dung KB. 22
7.3. Kiểm tra hai lượt trên web local: hệ thống ghép thông tin bổ sung thành cặp số 150/90. Trường hợp này do luật hội thoại xử lý, không phải đầu ra tự do của Qwen. 23
7.4. Phản hồi Qwen LoRA trên web local sau huấn luyện, kèm các đoạn nguồn truy xuất. 24

8.1. Hội thoại tiếp nối: bổ sung đơn vị và thời điểm đo cho số đường huyết đã nhập. 25
8.2. Màn hình phân loại: mẫu đầu vào và nhãn do checkpoint MLP trả về. 26
8.3. Màn hình hồi quy: biểu mẫu riêng và điểm tiến triển nghiên cứu. 27
8.4. Đồ thị lọc theo tài liệu a1c, lấy từ Neo4j. 28
8.5. Đối chiếu quan hệ Concept trong Neo4j Browser ở môi trường cục bộ. 29
8.6. Màn hình công bố nguồn gốc và phạm vi hai bộ dữ liệu. 30
8.7. Giao diện trợ lý tiểu đường với thanh điều hướng, vùng hội thoại và tài liệu đối chiếu. 31
8.8. Bố cục điện thoại: điều hướng hai hàng và hội thoại một cột. 34
8.9. Mở trích đoạn và liên kết nguồn ngay bên dưới câu trả lời. 35

Danh mục bảng

4.1. Danh mục dữ liệu thực sự dùng trong GlucoGuide. 6
4.2. Kiểm kê tám biến đầu vào trên toàn bộ CSV, trước tiền xử lý. 7
4.3. Nguồn thực sự được 21 tài liệu trong KB tham chiếu. 9

5.1. Phân loại trên 10.000 mẫu kiểm tra. 12
5.2. Hồi quy trên 89 mẫu kiểm tra. 12

7.1. Kiểm tra hình thức đầu ra trên hai nhóm test, mỗi nhóm 8 câu. 21

Chương 1

Giới thiệu

1.1. Bài toán và sản phẩm

Project xây dựng GlucoGuide, một ứng dụng web tích hợp hai nhánh xử lý của sơ đồ học phần. Nhánh dữ liệu sử dụng mô hình mạng nơ-ron nhiều lớp để phân loại nhãn nguy cơ tổng hợp và dự đoán điểm tiến triển bệnh trong dữ liệu nghiên cứu. Nhánh tri thức kế thừa kho tài liệu của tiểu luận 02, tổ chức các khái niệm cùng quan hệ trên Neo4j và truy xuất văn bản theo câu hỏi. Kết quả hai nhánh được trình bày cùng nguồn bằng chứng và nhật ký xử lý.

GlucoGuide phát triển từ các thực nghiệm học phần, bổ sung cơ chế phối hợp giữa mô hình, truy xuất và phản hồi. Toàn bộ kết quả đánh giá được lưu cùng mã nguồn để thuận tiện đối chiếu.

1.2. Phạm vi đầu ra

Hai bộ dữ liệu có định nghĩa nhãn khác nhau. Bộ phân loại gồm các nhãn High, Moderate và Low của dữ liệu tổng hợp. Bộ hồi quy gồm những người đã mắc bệnh và một thước đo tiến triển sau một năm. Vì vậy không thể ghép một nhãn High với một điểm hồi quy để suy ra xác suất mắc bệnh. Ứng dụng dùng hai biểu mẫu riêng và công bố phạm vi ngay tại đầu ra.

Bản công khai sử dụng tổng hợp trích đoạn xác định. Câu trả lời được ghép từ các đoạn văn truy xuất được và thông tin về phạm vi mô hình; không gọi mô hình ngôn ngữ bên ngoài. Bản cục bộ bổ sung Qwen3 1.7B tinh chỉnh LoRA để diễn đạt trên tài liệu truy xuất; các yêu cầu về thông số và thuốc vẫn qua luật. Hai chế độ đều phụ thuộc chất lượng và độ phủ của kho tài liệu.

1.3. Mục tiêu đánh giá

Phân loại được đo bằng accuracy và macro-F1. Hồi quy được đo bằng MAE và hệ số xác định. Truy xuất cần kiểm tra cả tài liệu được chọn và quan hệ có nguồn trên Neo4j. Kiểm tra ứng dụng tập trung vào các tình huống có bằng chứng, thiếu bằng chứng, thiếu đầu vào, giá trị không hợp lệ và cơ sở dữ liệu đồ thị không hoạt động.

Chương 2

Agent và cơ chế phối hợp

2.1. Vai trò xử lý

Hệ thống phân chia trách nhiệm thành tiếp nhận, kiểm tra dữ liệu, mô hình, tri thức, chính sách lựa chọn bước phản hồi, đối chiếu phạm vi và phản hồi. Bản triển khai hiện điều phối các vai trò này trong một tiến trình FastAPI. Nhật ký lưu người gửi, người nhận, loại thông điệp và nội dung. Đây là mô hình điều phối tập trung; các agent được gọi qua MessageBus với handler và bộ nhớ trong lượt, chưa chạy như những dịch vụ tự chủ độc lập.

Một thông điệp REQUEST thể hiện yêu cầu xử lý. INFORM ghi nhận kết quả và FAILURE thể hiện thành phần không thực hiện được. Khi Neo4j không hoạt động, hệ thống ghi FAILURE và chỉ dùng các đoạn văn cục bộ, không giả lập kết quả đồ thị. Khi thiếu đầu vào mô hình, hệ thống trả lại danh sách trường cần bổ sung trước khi suy luận.

2.2. Reinforcement Learning kết hợp luật

Chính sách được học trong môi trường mô phỏng luồng xử lý, không mô phỏng hiệu quả điều trị. Trạng thái gồm hai biến nhị phân: đã có kết quả mô hình và đã có bằng chứng truy xuất. Bốn trạng thái tương ứng với bốn tổ hợp của hai biến này. Ba hành động là hỏi làm rõ, trả lời có nguồn và giải thích mô hình kèm nguồn.

Hàm thưởng bằng một nếu hành động phù hợp trạng thái, bằng âm một trong trường hợp còn lại. Khi chưa có bằng chứng, hành động mục tiêu là hỏi làm rõ. Khi có bằng chứng nhưng chưa có kết quả mô hình, hành động mục tiêu là trả lời có nguồn. Khi có cả hai, hành động mục tiêu là giải thích mô hình và dẫn nguồn. Đây là hàm thưởng do người thiết kế quy định; không phải đánh giá của bệnh nhân hay chuyên gia.

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r - Q(s, a)].$$

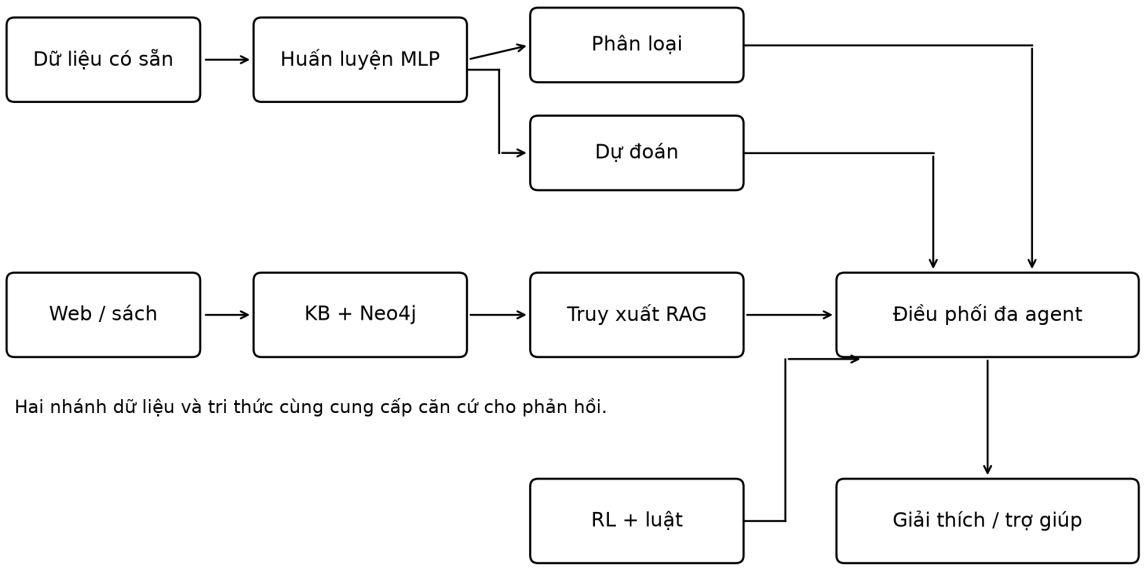
Mỗi episode kết thúc sau một hành động, nên không có thành phần bootstrap tương lai. Cấu hình gồm 3.000 episode, seed 254, tốc độ học 0,15 và xác suất khám phá 0,2. Vì bài toán chỉ có một bước, thí nghiệm minh họa cơ chế học giá trị hành động nhưng chưa chứng minh khả năng lập kế hoạch dài hạn. Luật thiếu bằng chứng luôn ép hành động hỏi làm rõ, kể cả khi chính sách học đề xuất hành động khác.

2.3. Giới hạn của kiến trúc

Việc hiển thị nhiều vai trò trong nhật ký không tự chứng minh tính tự chủ của một hệ đa agent. Bản hiện tại đã có handler và bộ nhớ theo lượt; hướng mở rộng là bộ nhớ hội thoại bền vững, cơ chế chất vấn khi có bất đồng và triển khai dịch vụ độc lập. Báo cáo phân biệt rõ những vai trò đã điều phối được với các năng lực còn cần phát triển.

Chương 3

Kiến trúc tổng quan



Hình 3.1: Hai nhánh hội tụ về điều phối và trợ giúp, dựng lại từ sơ đồ trên bảng.

3.1. Nhánh dữ liệu

DB có sẵn cung cấp dữ liệu cho quá trình huấn luyện. Pipeline phân loại gồm điền trung vị, chuẩn hóa và MLP. Pipeline hồi quy chuẩn hóa dữ liệu rồi suy luận bằng MLP. Hai đầu ra đều đi tới vùng phản hồi của ứng dụng. Trong lúc phục vụ, mô hình được nạp từ checkpoint; ứng dụng không huấn luyện lại theo câu hỏi của người dùng.

3.2. Nhánh tri thức

Nguồn tri thức là các đoạn văn đã được tổ chức trong tiểu luận 02. Mỗi tài liệu có mã, tiêu đề, từ khóa, văn bản, định danh nguồn và các bộ ba. Project bảo toàn những trường này khi chuyển sang kho tri thức mới. Việc cập nhật hướng dẫn y tế từ web chưa tự động hóa; phiên bản kho tài liệu phải được xem như một bản chụp dữ liệu cần rà soát trước khi mở rộng phạm vi sử dụng.

Một bộ ba gồm khái niệm đầu, tên quan hệ và khái niệm cuối. Neo4j lưu hai đầu dưới nhãn Concept; quan hệ RELATED_TO có thuộc tính label biểu diễn tên quan hệ, document biểu diễn tài liệu và evidence biểu diễn đoạn văn làm căn cứ. Ràng buộc duy nhất theo tên khái niệm và thao tác MERGE giúp nạp lại dữ liệu mà không tạo các bản sao giống hệt.

3.3. Luồng người dùng

Câu hỏi kiến thức được chuyển đến truy xuất. Yêu cầu mô hình phải đi qua kiểm tra các trường trước khi suy luận. Văn bản và kết quả đồ thị được chuyển sang đối chiếu; chính sách học và luật xác định kiểu phản hồi. Giao diện hiển thị câu trả lời, tài liệu nguồn và các bước xử lý. Lớp hội thoại nhận tối đa 64 thông điệp gần nhất để giải quyết câu hỏi tiếp nối; chỉ dùng câu hỏi người dùng làm gợi ý chủ đề, không dùng lời trả lời cũ làm căn cứ y tế. Các trường của hai mô hình được tách riêng để tránh biến đổi sai đơn vị hoặc tự suy diễn giá trị còn thiếu.

Chương 4

Nguồn dữ liệu và quy trình chuẩn bị

4.1. Phân biệt dữ liệu mô hình với tài liệu tri thức

Project sử dụng hai bộ dữ liệu học có giám sát và một kho tài liệu. Bộ phân loại cung cấp nhãn High, Moderate, Low; bộ hồi quy cung cấp một điểm tiến triển sau một năm; KB cung cấp văn bản giải thích và nguồn. Ba thành phần này có mục tiêu khác nhau. Dữ liệu mô hình không tự trở thành hướng dẫn y khoa, còn tài liệu y khoa không được coi là nhãn huấn luyện cho hai MLP.

Bảng 4.1: Danh mục dữ liệu thực sự dùng trong GlucoGuide.

Thành phần	Quy mô	Nơi lấy và nơi sử dụng
Phân loại	50.000 dòng, 41 cột gốc; dùng 8 biến	Kaggle, Diabetes Risk Prediction Dataset (50K patients), tài khoản mobeenfatimah. ZIP lưu tại `data/raw/diabetes.zip`; dùng trong `scripts/train_models.py`.
Hồi quy	442 dòng, 10 biến và target số	Bộ diabetes đi kèm scikit-learn, đọc bằng `load_diabetes(scaled=False)`. Không dùng ZIP của bài toán phân loại.
Tri thức	22 đoạn; 9 nguồn đang được tham chiếu	`data/knowledge.json`; 20 đoạn kế thừa kho tiểu luận 02 và hai đoạn bổ sung về phạm vi phân loại và định nghĩa tiểu đường. 32 bộ ba được nạp lên Neo4j.

4.2. Nguồn và phiên bản bộ phân loại

Trang công bố bộ dữ liệu:
https://www.kaggle.com/datasets/mobeenfatimah/diabetes-risk-prediction-dataset-50k-patients.

Tệp nằm trong ZIP có tên `diabetes_risk_prediction_dataset.csv`. Báo cáo sử dụng đúng bản chụp dữ liệu đã lưu trên máy, không tự thay bằng bộ 100.000 bản ghi của bài

tham khảo. Tệp kiểm kê `results/data_audit.json` lưu SHA-256 của ZIP để phân biệt các phiên bản tải về.

Đơn vị quan sát là một bản ghi tổng hợp, không phải hồ sơ lâm sàng được project thu thập. Cột mục tiêu là `Diabetes_Risk`. Kiểm kê trực tiếp thấy 36.593 nhãn High, 12.937 Moderate và 470 Low, tương ứng 73,186%, 25,874% và 0,94%. Một mô hình chỉ đoán High sẽ có accuracy 73,186% trên toàn bộ bản chụp dữ liệu; vì vậy phải đọc accuracy cùng macro-F1 và recall từng lớp.

Không có nhãn thiếu và không có dòng trùng hoàn toàn trên 41 cột. Kết luận về dòng trùng không chứng minh các hồ sơ là những cá nhân độc lập, nhất là khi bảng có cột định danh. Pipeline hiện giữ nguyên 50.000 dòng, không có bước loại trùng hay loại ngoại lệ. Những đặc điểm này được công bố để người đọc biết chính xác dữ liệu nào đã đi vào phép chia.

4.3. Từ điển đầu vào và giá trị thiếu

Bảng 4.2: Kiểm kê tám biến đầu vào trên toàn bộ CSV, trước tiền xử lý.

Biến	Số ô thiếu	Min / trung vị / max
Age	497	18 / 54 / 90
BMI	0	11.9 / 30 / 61.7
HbA1c	1974	4.5 / 8.5 / 12.5
Fasting_Blood_Sugar	0	65 / 142.6 / 220
Blood_Glucose	959	70 / 159.9 / 250
Blood_Pressure_Systolic	0	90 / 140 / 190
HDL	1000	25 / 57.3 / 90
LDL	1000	50 / 135.1 / 220

Các cột được chọn lần lượt là tuổi, BMI, HbA1c, đường huyết lúc đói, glucose, huyết áp tâm thu, HDL và LDL. Min, trung vị, max ở Bảng 4.2 là thống kê mô tả của bản chụp dữ liệu, không phải khoảng bình thường hay ngưỡng chẩn đoán. Trên giao diện, nút điền mẫu lấy đúng giá trị của bộ dữ liệu. Người dùng không nên tự thay một chỉ số ở đơn vị khác rồi coi kết quả tương đương.

Những trường `Patient_ID`, `Diabetes_Risk_Score`, `AI_Health_Recommendation` và `Doctor_Consultation_Needed` không được chọn làm đặc trưng. Đặc biệt, điểm nguy cơ và khuyến nghị có thể gắn trực tiếp với quy trình tạo nhãn; đưa chúng vào dễ khiến bài toán trở thành khôi phục thông tin đã gần như có sẵn. Việc bỏ các trường này giảm một nguy cơ rò rỉ, nhưng không chứng minh mọi phụ thuộc trong dữ liệu tổng hợp đã được loại bỏ.

Trung vị dùng để điền thiếu được học trên tập train của pipeline, không dùng trung vị của

toàn bộ bảng ở Bảng 4.2. Sau đó StandardScaler học trung bình và độ lệch chuẩn trên train. Pipeline chứa cả imputer, scaler và mô hình được lưu bằng joblib, nhờ đó web dùng cùng phép biến đổi với quá trình huấn luyện. Khi nhập từ web, các trường hiện vẫn bắt buộc; imputer chủ yếu phục vụ giá trị thiếu trong dữ liệu huấn luyện và kiểm tra.

4.4. Phép chia và dấu vết tái lập

Phân loại chia 80/20, phân tầng theo nhãn, seed 254: 40.000 dòng train và 10.000 dòng test. Chỉ số dòng bắt đầu từ 0 và nhãn train/test được lưu tại `results/classification_split.csv`. Tập test có 7.319 High, 2.587 Moderate và 94 Low. Kiểm kê dữ liệu không huấn luyện lại mô hình và không thay kết quả đã báo cáo.

MLP bật early stopping với phần validation nội bộ của thư viện. Validation này nằm bên trong train ngoài, nhưng imputer và scaler đã fit trước khi MLP tách validation. Đây là điểm cần cải thiện nếu thiết kế một thí nghiệm chọn mô hình nghiêm ngặt. Test ngoài không được dùng để fit pipeline. Báo cáo không nhận rằng đã có ba tập train/validation/test tách trước toàn bộ tiền xử lý.

4.5. Nguồn bộ hồi quy và ý nghĩa mục tiêu

Nguồn phân phối:

https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html.

Nguồn gốc được thư viện dẫn tới nghiên cứu Least Angle Regression và trang dữ liệu thống kê:

https://www4.stat.ncsu.edu/~boos/var.select/diabetes.html.

Bộ dữ liệu gồm 442 người đã mắc bệnh với mục tiêu là một đại lượng tiến triển sau một năm; mô tả của thư viện không cho phép đổi mục tiêu đó thành đường huyết hoặc xác suất mắc bệnh[12].

Project gọi `scaled=False`, sau đó chuẩn hóa bằng scaler của riêng train. Mười cột gồm age, sex, bmi, bp và s1 đến s6. age là tuổi, bmi là chỉ số khối cơ thể, bp là huyết áp trung bình. Theo metadata, s1 là cholesterol toàn phần, s2 LDL, s3 HDL, s4 tỷ lệ cholesterol/HDL, s5 được mô tả thận trọng là có thể là log triglyceride, s6 là chỉ số đường huyết. sex được giữ nguyên mã nghiên cứu; không dùng mã này để tự chọn ngưỡng y khoa.

Bộ hồi quy không có giá trị thiếu trong ma trận đặc trưng. Phép chia ngẫu nhiên seed 254 giữ 353 mẫu train và 89 mẫu test, ghi tại `results/regression_split.csv`. Hai mô hình cùng dùng phép chia này. Chỉ số dòng trong `results/regression_predictions.csv` cho phép truy lại mục tiêu thật và dự đoán của từng mẫu test.

4.6. Nguồn KB và nguồn đang thực sự được dùng

Bảng 4.3: Nguồn thực sự được 21 tài liệu trong KB tham chiếu.

Nguồn	Mã tài liệu	Số đoạn
NIDDK · Xét nghiệm & chẩn đoán	a1c, testing	2
CDC · Xử trí hạ đường huyết	low, urgent	2
CDC · Lập kế hoạch bữa ăn	plate, carb, fruit	3
WHO · Diabetes	activity, symptoms	2
NIDDK · Quản lý bệnh tiểu đường	medicine, monitor	2
scikit-learn · Dữ liệu diabetes	meanpressure, triglyceride, demographics, model	4
AHA · Hiểu số đo huyết áp	bloodpressure	1
MedlinePlus · Các chỉ số cholesterol	lipids, hdl, ldl, ratio	4
Bộ dữ liệu tổng hợp Diabetes Risk Prediction 50K	classification_scope	1

diagnosis: https://www.niddk.nih.gov/health-information/diabetes/overview/tests-diagnosis

low: https://www.cdc.gov/diabetes/treatment/treatment-low-blood-sugar-hypoglycemia.html

meal: https://www.cdc.gov/diabetes/healthy-eating/diabetes-meal-planning.html

who: https://www.who.int/news-room/fact-sheets/detail/diabetes

care: https://www.niddk.nih.gov/health-information/diabetes/overview/managing-diabetes

dataset: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html

pressure: https://www.heart.org/en/health-topics/high-blood-pressure/understanding-blood-pressure-readings

lipids: https://medlineplus.gov/cholesterollevelswhatyouneedtoknow.html

classification_data: https://www.kaggle.com/datasets/mobeenfatimah/diabetes-risk-prediction-dataset-50k-patients Danh mục sources trong JSON có 13 mục, nhưng chỉ 9 mục đang được tài liệu tham chiếu; không được ghi rằng cả 13 nguồn đều

đóng góp vào phản hồi hiện tại. Mỗi đoạn có id, title, terms, text, source và triples. Các đoạn này là bản biên soạn ngắn kế thừa và mô tả kỹ thuật của project, không phải toàn văn sách hoặc bản tải tự động từ website.

Luồng Web/sách đến KB trong sơ đồ được hiện thực ở mức biên soạn bản chụp dữ liệu có nguồn. Project chưa có nút upload PDF, trình thu thập web, cơ chế cập nhật định kỳ hay bộ chia chương sách tự động. Các PDF tham khảo của sinh viên chỉ phục vụ bố cục và phân tích thiết kế; chúng không được nạp làm nguồn tư vấn y khoa. Khi thay KB cần rà nội dung, cập nhật JSON, chạy lại script nạp Neo4j và khởi động lại backend để xây lại ma trận TF-IDF.

Hai mươi đoạn kế thừa chứa 32 bộ ba. Đoạn `classification_scope` bổ sung giải thích nhãn tổng hợp và không có bộ ba, do đó số đoạn tăng lên 21 nhưng số cạnh vẫn là 32. Theo quy tắc MERGE hiện tại, các cạnh tạo 60 nút Concept. Các số đếm JSON là kiểm kê dữ liệu nguồn; số nút/cạnh trên web được lấy trực tiếp từ cơ sở dữ liệu để xác nhận nạp thành công.

4.7. Từ nguồn tới kết quả hiển thị

Đường đi phân loại là ZIP/CSV, chọn cột, chia dữ liệu, fit pipeline, lưu checkpoint, API và giao diện. Đường đi hồi quy là hàm tải của thư viện, chia dữ liệu, fit pipeline, checkpoint và API. Đường đi tri thức là đoạn văn có nguồn, chỉ mục TF-IDF và bộ ba Neo4j, lựa chọn bằng chứng rồi tổng hợp trích đoạn.

Các tệp `results/model_metrics.json`, `results/classification_predictions.csv`, `results/regression_predictions.csv` và `results/api_scenarios.json` lần lượt lưu số liệu tổng hợp, dự đoán chi tiết và kiểm thử chức năng. Script `scripts/audit_data.py` sinh bảng dữ liệu của báo cáo và bản danh mục dùng trên web từ cùng một bản chụp dữ liệu. Tách thống kê dữ liệu, metric mô hình và kiểm thử API giúp tránh coi việc ứng dụng chạy thành công là bằng chứng mô hình dự đoán tốt.

Chương 5

Các thành phần và thực nghiệm

5.1. Phân loại

Dữ liệu tổng hợp gồm 50.000 dòng. Tám biến đầu vào là tuổi, BMI, HbA1c, đường huyết lúc đói, glucose, huyết áp tâm thu, HDL và LDL. Các biến chứa điểm nguy cơ, khuyến nghị sức khỏe và yêu cầu gặp bác sĩ không được đưa vào mô hình. Phép chia phân tầng với seed 254 giữ 40.000 dòng huấn luyện và 10.000 dòng kiểm tra.

MLP có ba tầng ẩn 64, 32 và 16 đơn vị, dừng sớm và tối đa 150 vòng lặp. Trung vị và tham số chuẩn hóa được học trên tập huấn luyện ngoài. Cơ chế early stopping của thư viện chia tiếp một phần dữ liệu cho validation; do tiền xử lý nằm trước MLP, các tham số tiền xử lý đã nhìn thấy phần validation nội bộ này. Tập test ngoài vẫn độc lập, nhưng để kiểm soát validation nghiêm ngặt hơn cần tách validation trước toàn bộ pipeline.

Logistic Regression dùng trọng số lớp cân bằng làm đối chứng. MLP dùng cấu hình mặc định không cân bằng trọng số. Vì hai cấu hình có cách xử lý mất cân bằng khác nhau, chênh lệch kết quả không chỉ phản ánh kiến trúc mạng. Accuracy cần đọc cùng macro-F1, đặc biệt với lớp Low hiếm.

5.2. Hồi quy

Bộ diabetes từ scikit-learn được tải ở dạng chưa chuẩn hóa, gồm 442 quan sát với 10 biến đầu vào. Phép chia seed 254 giữ 353 mẫu huấn luyện và 89 mẫu kiểm tra. Ridge với hệ số điều chuẩn 10 là đối chứng. MLP có ba tầng ẩn 64, 32 và 16, dừng sớm và tối đa 1.000 vòng lặp.

Các biến s1 đến s6 là những trường nghiên cứu của bộ dữ liệu. Không được thay tên hoặc đơn vị bằng suy đoán khi nhập hồ sơ ngoài đời. Mục tiêu của demo là minh họa quy trình suy luận từ mô hình đã lưu. Chất lượng trên bộ dữ liệu nhỏ không chứng minh khả năng chuyển sang quần thể Việt Nam.

5.3. Kết quả kiểm tra

MLP cải thiện accuracy và macro-F1 so với Logistic Regression trong lần chạy này. Tuy nhiên macro-F1 còn thấp so với accuracy, phản ánh hiệu năng không đồng đều giữa các lớp. Ở hồi

Bảng 5.1: Phân loại trên 10.000 mẫu kiểm tra.

Mô hình	Accuracy	Macro-F1
Logistic Regression	0.6965	0.5005
MLP	0.8180	0.5441

Bảng 5.2: Hồi quy trên 89 mẫu kiểm tra.

Mô hình	MAE	R^2
Ridge	44.0555	0.4791
MLP	44.3225	0.4758

quy, Ridge có MAE thấp hơn và hệ số xác định cao hơn MLP. Báo cáo vẫn trình diễn MLP để minh họa nhánh Deep Learning, đồng thời công bố đầy đủ đối chứng và không nhận MLP là mô hình tốt nhất.

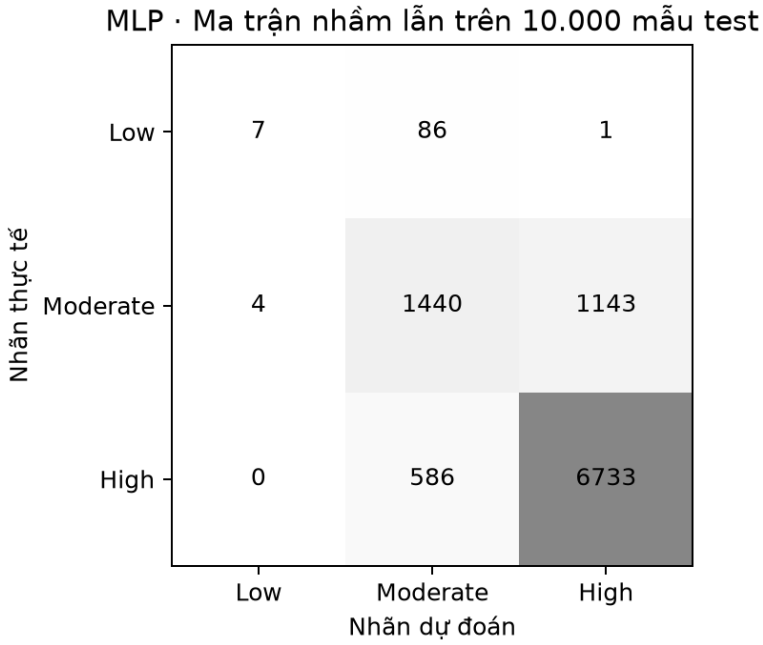
5.4. Truy xuất và đồ thị

Văn bản được biểu diễn bằng TF-IDF với unigram và bigram, bỏ dấu khi chuẩn hóa. Câu hỏi được biến đổi bằng cùng từ vựng. Điểm truy xuất là tích vô hướng của các vector đã chuẩn hóa. Hệ thống giữ tối đa ba đoạn có điểm lớn hơn giá trị lớn nhất giữa 0,04 và 65% điểm của đoạn đứng đầu. Ngưỡng này là quy tắc triển khai chưa được chọn trên một bộ validation độc lập.

Neo4j lấy các cạnh có thuộc tính document trùng với mã tài liệu đã truy xuất. Do đó đồ thị cung cấp cấu trúc và căn cứ bổ sung cho truy xuất văn bản; đây chưa phải một bộ máy suy luận đa bước tổng quát. Một nhãn quan hệ không chứng minh quan hệ nhân quả. Khi không có tài liệu đủ điểm, hệ thống yêu cầu người dùng làm rõ.

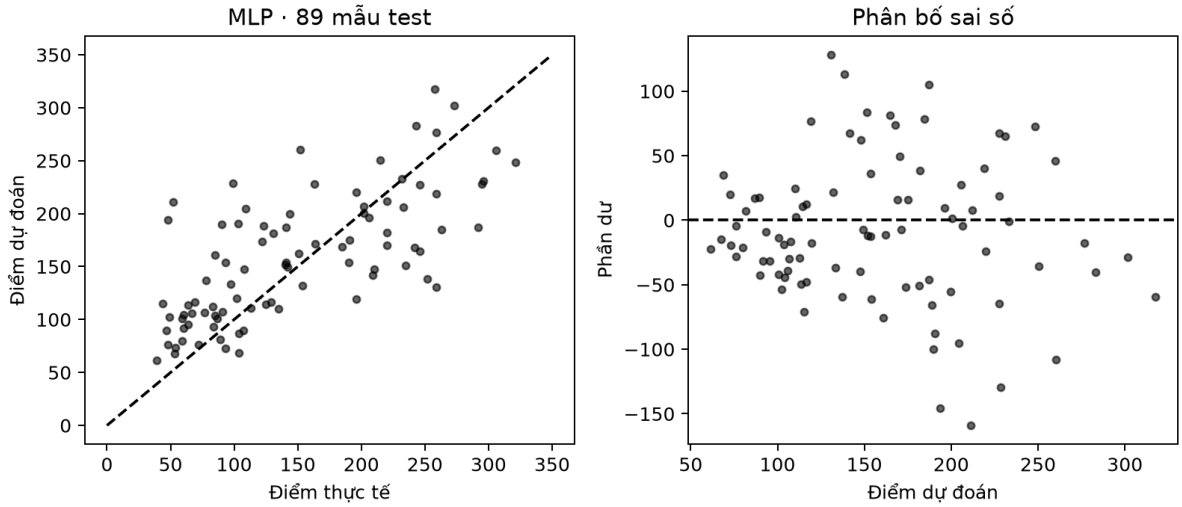
5.5. Phân tích sai số theo lớp

Ma trận nhầm lẫn được tạo từ toàn bộ 10.000 dự đoán ngoài mẫu, không lấy từ tập huấn luyện. Tập test có 7.319 mẫu High, 2.587 mẫu Moderate và 94 mẫu Low. MLP dự đoán đúng 6.733 mẫu High, 1.440 mẫu Moderate nhưng chỉ 7 mẫu Low. Vì vậy accuracy 81,8% che giấu khả năng nhận diện lớp hiếm còn yếu. Recall của Low chỉ khoảng 7,45%; kết quả này cho thấy hạn chế đáng kể ở lớp hiếm. Tỷ lệ lỗi giữa Moderate và High cho thấy ranh giới của nhãn tổng hợp chưa được mô hình tách tốt. Cải thiện tiếp theo cần so sánh trọng số lớp, điều chỉnh ngưỡng và cách lấy mẫu trên validation, đồng thời giữ nguyên test để tránh chọn cấu hình theo kết quả test. Không đổi tên nhãn tổng hợp thành chẩn đoán y tế.



Hình 5.1: Ma trận nhầm lẫn của MLP trên tập kiểm tra phân tầng.

5.6. Phân tích phần dư hồi quy



Hình 5.2: Dự đoán và phần dư của MLP trên 89 mẫu kiểm tra.

Đường chéo thể hiện dự đoán bằng giá trị thật. Những điểm cách xa đường chéo đóng góp lớn vào MAE. Phần dư được tính bằng giá trị thực trừ dự đoán; phần dư dương biểu thị dự đoán thấp hơn thực tế. Không thể dùng một chỉ số tổng hợp để bảo đảm mọi nhóm đầu vào có sai số tương đương. Bản này chưa xây dựng khoảng dự báo và chưa hiệu chỉnh bất định.

5.7. Hợp đồng dữ liệu và API

GET /api/schema cung cấp thứ tự đặc trưng. GET /api/examples cung cấp một mẫu từ mỗi bộ dữ liệu để trình diễn. POST /api/chat nhận question, task và values. Với task knowledge, hệ thống truy xuất văn bản; với classification hoặc regression, values phải đủ các trường tương ứng. Kết quả gồm answer, result, sources, graph_evidence và trace.

Trường result của phân loại gồm label, scores và scope. scores là đầu ra xác suất lớp của mô hình trên nhãn tổng hợp, chưa được hiệu chỉnh. Trường result của hồi quy gồm value và scope. Việc tách cấu trúc này tránh dùng chung một con số cho hai ý nghĩa khác nhau. Dữ liệu mẫu là mẫu của bộ nghiên cứu, không phải hồ sơ do người dùng cung cấp.

Kiểm tra đầu vào hiện yêu cầu số hữu hạn, giới hạn trị tuyệt đối và đủ số trường. Đây là kiểm tra kỹ thuật, chưa phải kiểm định lâm sàng từng đơn vị. Giá trị nhập bằng số nhưng sai đơn vị vẫn có thể làm kết quả vô nghĩa; vì vậy demo được giới hạn ở dữ liệu nghiên cứu và có nút điền mẫu.

5.8. Kết quả kiểm thử tích hợp

Script test_scenarios.py thực hiện tám trường hợp: câu hỏi có nguồn; câu hỏi ngoài từ vựng; suy luận phân loại; suy luận hồi quy; thiếu trường; giá trị không hữu hạn; tên bài toán không hợp lệ; lỗi Neo4j có kiểm soát. Tám trường hợp đều đạt điều kiện kiểm tra ở lần chạy lưu trong results/api_scenarios.json. Kiểm tra lỗi cơ sở dữ liệu được thực hiện bằng thay thế driver trong test, không phải chủ động tắt cơ sở dữ liệu đang phục vụ người dùng.

Kiểm thử xác nhận hợp đồng phản hồi và nhánh lỗi, chưa đo độ chính xác truy xuất trên tập câu hỏi lớn. Trường hợp ngoài miền sử dụng chuỗi không có trong từ vựng, do đó không chứng minh hệ thống phát hiện mọi câu hỏi ngoài miền bằng tiếng Việt. Những giới hạn này giúp tách kiểm thử chức năng khỏi đánh giá chất lượng tư vấn.

5.9. Đối chiếu với sơ đồ yêu cầu

Thành phần	Hiện thực trong sản phẩm
DB và Deep Learning	Hai bộ dữ liệu tách biệt, MLPClassifier và MLPRegressor; có checkpoint và kết quả test.
Phân loại và dự đoán	Hai lựa chọn trong phòng thực nghiệm, cùng chuyển kết quả đến phản hồi và nhật ký.
Web/sách đến KB	Kế thừa KB đã biên soạn từ tiểu luận 02; bảo toàn mã nguồn tài liệu, không tự động thu thập web ở thời điểm chạy.

KB và RAG	TF-IDF chọn đoạn văn; Neo4j trả các quan hệ cùng mã tài liệu; phản hồi trích đoạn có nguồn.
Agent và RL + rule	Handler và MessageBus xử lý yêu cầu; chính sách học một bước chọn kiểu phản hồi, luật chặn thiếu bằng chứng.
Tư vấn, trợ giúp	Chatbot giải thích kiến thức và phạm vi đầu ra; chưa sinh đối thoại tự do bằng LLM.

Chương 6

Code và demo

6.1. Địa chỉ và cách chạy

Demo công khai

https://glucoguide-giang254.vercel.app

Mã nguồn

https://github.com/jellalaz/He_Thong_Thong_Minh_Thay_Que

Demo cục bộ

http://localhost:8765

Neo4j Browser cục bộ

http://localhost:7474/browser/

Địa chỉ localhost dành cho máy chạy dịch vụ. Bản demo công khai kết nối Neo4j AuraDB Free.

Cài requirements.txt để chạy ứng dụng; dùng requirements-training.txt khi huấn luyện và tái lập thực nghiệm. Chạy `scripts/train_models.py` để tạo checkpoint, `scripts/train_policy.py` để tạo chính sách và `scripts/ingest_graph.py` để nạp đồ thị. Sau đó chạy uvicorn app.main:app từ thư mục project. Cấu hình Neo4j nằm trong .env và không đưa lên repository.

6.2. Kịch bản trình diễn

Kịch bản thứ nhất: hỏi "HbA1c là gì?". Kiểm tra câu trả lời có mã tài liệu, kiểm tra bước truy xuất và số quan hệ Neo4j. Kịch bản thứ hai: hỏi một chủ đề không có trong kho, chẳng hạn lịch sử một đội bóng. Hệ thống phải yêu cầu làm rõ hoặc báo thiếu bằng chứng, không tự tạo nguồn.

Kịch bản thứ ba: nhập đủ tám trường phân loại bằng một mẫu của dữ liệu. Ghi lại nhãn, thông báo phạm vi và nhật ký mô hình. Kịch bản thứ tư: nhập đủ mười trường hồi quy từ mẫu nghiên cứu, kiểm tra đầu ra số và thông báo đây là điểm tiến triển. Hai kịch bản không dùng chung biểu mẫu.

Kịch bản thứ năm: bỏ một trường bắt buộc. Hệ thống phải nêu trường còn thiếu. Kịch

bản thứ sáu: nhập giá trị không hữu hạn hoặc chuỗi ký tự vào API, hệ thống phải từ chối. Kịch bản thứ bảy: tắt Neo4j rồi hỏi kiến thức, kiểm tra nhật ký FAILURE và việc công bố chỉ dùng văn bản. Kịch bản thứ tám: mở Neo4j Browser và thực hiện truy vấn dưới đây để đối chiếu với giao diện đồ thị.

```
MATCH (a:Concept)-[r:RELATED_TO]->(b:Concept)
RETURN a,r,b LIMIT 100;
```

6.3. Hạn chế và hướng hoàn thiện

Hệ thống duy trì ngữ cảnh chủ đề trong phiên nhưng chưa có bộ nhớ hội thoại bền vững, chưa đọc phiếu xét nghiệm, nhánh Qwen local mới được đánh giá trên tập nội bộ nhỏ và chưa có hội đồng tranh biện độc lập. Kiểm chứng mô hình mới chỉ dùng một seed; chưa có đánh giá chuyên gia, chưa có dữ liệu ngoài miền và chưa kiểm thử tải lớn. RL học quy trình mô phỏng, không quyết định điều trị.

Hướng ưu tiên là mở rộng giao thức agent và bộ nhớ hội thoại, mở rộng tập câu hỏi đánh giá truy xuất độc lập, bổ sung kiểm tra đơn vị có nguồn và cập nhật KB từ tài liệu được kiểm chứng. Sau khi có các thành phần đó mới đánh giá lợi ích phối hợp so với từng thành phần đơn lẻ bằng các phép loại bỏ thành phần trên cùng tập kiểm tra.

6.4. Triển khai công khai trên Vercel và Neo4j Aura

GlucoGuide – bản demo công khai
https://glucoguide-giang254.vercel.app

6.4.1. Kiến trúc triển khai

Vercel Hobby phục vụ giao diện và API FastAPI từ cùng tên miền. Các checkpoint dữ liệu bảng và nhận diện ý định được đóng gói cùng mã nguồn; đồ thị nằm trên Neo4j AuraDB Free. Vì vậy bản demo không phụ thuộc tiến trình chạy trên máy cá nhân. Người xem không cần cài Neo4j hoặc đăng nhập để sử dụng bốn chức năng trên web.

Các biến môi trường kết nối (URI, tài khoản, mật khẩu và tên cơ sở dữ liệu) được cấu hình trên máy chủ. Trình duyệt gọi API của ứng dụng, không nhận thông tin đăng nhập cơ sở dữ liệu. Các tệp môi trường, dữ liệu thô và tài liệu báo cáo không được đóng gói vào hàm phục vụ web.

6.4.2. Nạp dữ liệu và kiểm tra

Script `scripts/ingest_graph.py` nạp kho tri thức theo phép MERGE để có thể chạy lại. Tùy chọn `--https` sử dụng Query API khi môi trường phát triển không kết nối được Bolt. Đồ thị triển khai có 60 nút Concept và 32 quan hệ; kho văn bản ở lần kiểm tra công khai trước gồm 21 đoạn; bản mã nguồn mới bổ sung đoạn định nghĩa tiểu đường, thành 22 đoạn.

Ngày 05/11/2026, script `scripts/check_deployment.py` đã kiểm tra thành công 12 nhóm điều kiện trên địa chỉ công khai, gồm tải giao diện, trạng thái cơ sở dữ liệu, đồ thị, hội thoại có căn cứ, câu hỏi tiếp nối, thiếu đơn vị, câu ngoài phạm vi, nhận diện tình huống cần trợ giúp, hai bài toán mô hình, dữ liệu đầu vào không hợp lệ và tra cứu KB. Kết quả lưu tại `results/deployment_checks.json`. Kiểm tra này xác nhận các tình huống đã chạy; không thay thế đánh giá chuyên gia hoặc kiểm thử tải.

6.4.3. Vận hành trong gói miễn phí

Triển khai sử dụng Vercel Hobby và AuraDB Free. Không bật dịch vụ trả phí. Tài nguyên và thời gian đáp ứng phụ thuộc giới hạn của hai gói; lần gọi đầu có thể chậm do khởi động hàm. Chủ tài khoản cần theo dõi trạng thái Aura khi lâu không sử dụng, giữ bản sao dữ liệu và có thể nạp lại bằng script đã cung cấp.

Để xem trực tiếp bằng Neo4j, chủ tài khoản mở Aura Console, chọn instance và mục Query; thực hiện câu lệnh MATCH trong kịch bản trình diễn. Khách xem dùng mục Đồ thị trên web. Bản Neo4j cục bộ vẫn dùng được cho phát triển nhưng không phải điều kiện để demo công khai hoạt động.

Chương 7

Tinh chỉnh mô hình hội thoại trên máy cá nhân

7.1. Mục tiêu và phạm vi

Các câu hỏi thử cho thấy phản hồi theo mẫu còn cứng và dễ thiếu bối cảnh. Nhánh hội thoại cục bộ bổ sung Qwen3 1.7B để diễn đạt kiến thức lấy từ KB. Mô hình nền đã được Qwen tiền huấn luyện; thực nghiệm này chỉ tinh chỉnh LoRA trên ví dụ tiếng Việt của project. Việc tải mô hình không được tính là một lần huấn luyện.

Suy luận diễn ra trên máy cá nhân, không gọi dịch vụ mô hình ngôn ngữ bên ngoài. Bản Vercel tiếp tục phục vụ KB, luật và các mô hình dữ liệu bảng; checkpoint Qwen không chạy trong hàm Vercel. Hai chế độ dùng chung giao diện nhưng có điều kiện vận hành khác nhau.

7.2. Dữ liệu và thiết kế đánh giá

7.2.1. Nguồn và cách xây dựng

Tệp `experiments/local_qwen/dataset.json` chứa các cặp chỉ dẫn và phản hồi do project biên soạn từ các đoạn KB có nguồn. Mỗi mẫu lưu câu hỏi, lịch sử, mã đoạn kiến thức và câu trả lời đích. Nguồn KB gồm các tài liệu sức khỏe đã liệt kê trong danh mục. Đây không phải dữ liệu bệnh án và chưa được chuyên gia y tế thẩm định.

Tập huấn luyện gồm 76 mẫu; tập validation gồm 21 mẫu diễn đạt khác nhưng cùng nguồn KB. Tập test gồm 16 mẫu, chia đều thành nhóm kiến thức và nhóm hội thoại. Kiểm tra chuẩn hóa câu hỏi loại trùng lặp trực tiếp giữa các tập. Tuy vậy, cùng nguồn và cùng cách biên soạn làm giới hạn tính độc lập của đánh giá. Hai nhóm test không được gọi là hai bộ dữ liệu lâm sàng độc lập.

7.2.2. Đối chiếu trước và sau tinh chỉnh

Mô hình nền và checkpoint LoRA nhận cùng tài liệu, câu hỏi, lịch sử và giới hạn sinh. Chọn checkpoint bằng loss validation, không dùng điểm test để chọn epoch. Nhóm kiến thức kiểm tra trả lời đúng trọng tâm và dẫn mã nguồn; nhóm hội thoại kiểm tra thông tin thiếu, câu hỏi tiếp nối, lời cảm ơn, yêu cầu thuốc và câu ngoài phạm vi. Loss giảm chỉ cho thấy mô hình khớp câu trả lời đích tốt hơn; không đủ kết luận độ chính xác y tế tăng.

7.3. Cấu hình và quá trình học

Máy thực nghiệm có Intel Core i9-14900HX, RAM khoảng 16 GB và NVIDIA GeForce RTX 4060 Laptop GPU 8 GB. Mô hình nền được tải từ kho chính thức:

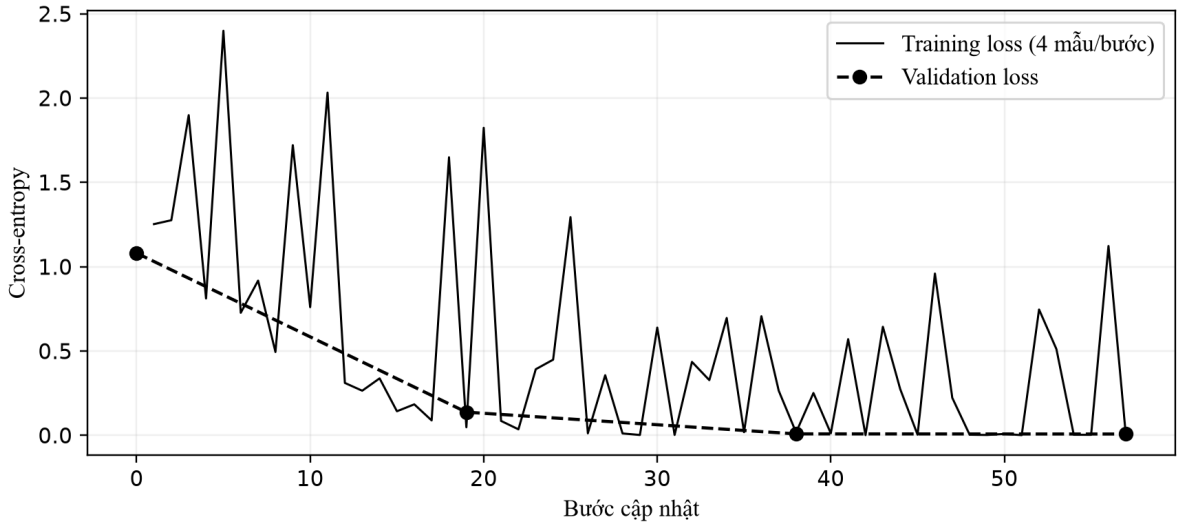
Qwen3 1.7B
https://huggingface.co/Qwen/Qwen3-1.7B

LoRA giữ cố định trọng số nền W và học hai ma trận nhỏ để tạo $W' = W + \frac{\alpha}{r}BA$. Cấu hình dùng hạng $r = 8$, $\alpha = 16$, dropout 0,05, áp dụng vào các phép chiếu query và value. Hàm mất mát chỉ tính trên token câu trả lời, bỏ qua phần chỉ dẫn và tài liệu.

Batch size bằng 1 nghĩa là một mẫu được xử lý trong mỗi lượt lan truyền; tích lũy gradient qua 4 mẫu trước khi cập nhật. Một epoch đi qua toàn bộ tập train. AdamW cập nhật tham số từ gradient với learning rate 10^{-4}. Thực nghiệm đặt 3 epoch, tối đa 768 token cho một mẫu, dùng BF16 và gradient checkpointing để giảm bộ nhớ. Training loss theo bước và validation loss theo epoch được lưu riêng để theo dõi khả năng khái quát hóa.

7.3.1. Kết quả đo trên máy thực nghiệm

Số tham số được tối ưu là 1,605,632, trên tổng 1,722,180,608 tham số. Checkpoint được chọn ở epoch 3. Loss validation của mô hình nền là 1.0810; giá trị tốt nhất sau tinh chỉnh là 0.0082. Thời gian ba epoch, gồm đánh giá validation và lưu checkpoint, là 1.97 phút. Bộ nhớ GPU cấp phát đỉnh do PyTorch ghi nhận là 3.93 GiB; số này không bao gồm toàn bộ bộ nhớ các ứng dụng khác.



Hình 7.1: Loss huấn luyện theo bước và validation theo epoch. Điểm đầu validation thuộc mô hình nền.

Mô hình	Nhóm	Có dẫn mã	Mã lạ	Chạm giới hạn	Giây/câu
Qwen nền	Kiến thức	0/8	0	0	8.07
Qwen nền	Hội thoại	0/8	0	0	4.97
Qwen LoRA	Kiến thức	8/8	0	0	7.57
Qwen LoRA	Hội thoại	7/8	1	0	4.93

Bảng 7.1: Kiểm tra hình thức đầu ra trên hai nhóm test, mỗi nhóm 8 câu.

Có dẫn mã chỉ kiểm tra sự xuất hiện của mã tài liệu, không chứng minh trích dẫn hỗ trợ đầy đủ câu trả lời. Mã lạ là mã không nằm trong ngữ cảnh đã cấp. Chạm giới hạn nghĩa là sinh đủ 320 token, có nguy cơ câu bị cắt. Độ trễ được đo sau khi mô hình đã nạp, không gồm thời gian khởi động hoặc truy xuất Neo4j. Hai mô hình dùng cùng ngữ cảnh được chỉ định trước để tách ảnh hưởng của bộ sinh; kết quả này chưa đo toàn bộ pipeline truy xuất.

Tệp `results/local_qwen/base_answers.json` và `results/local_qwen/lora_answers.json` lưu nguyên văn từng phản hồi. Tệp `results/local_qwen/training_summary.json` lưu cấu hình, mã băm dữ liệu và tài nguyên đo được. Các tệp này cho phép kiểm tra lại kết luận mà không cần dựa vào ảnh minh họa.

7.3.2. Phân tích phản hồi và giới hạn

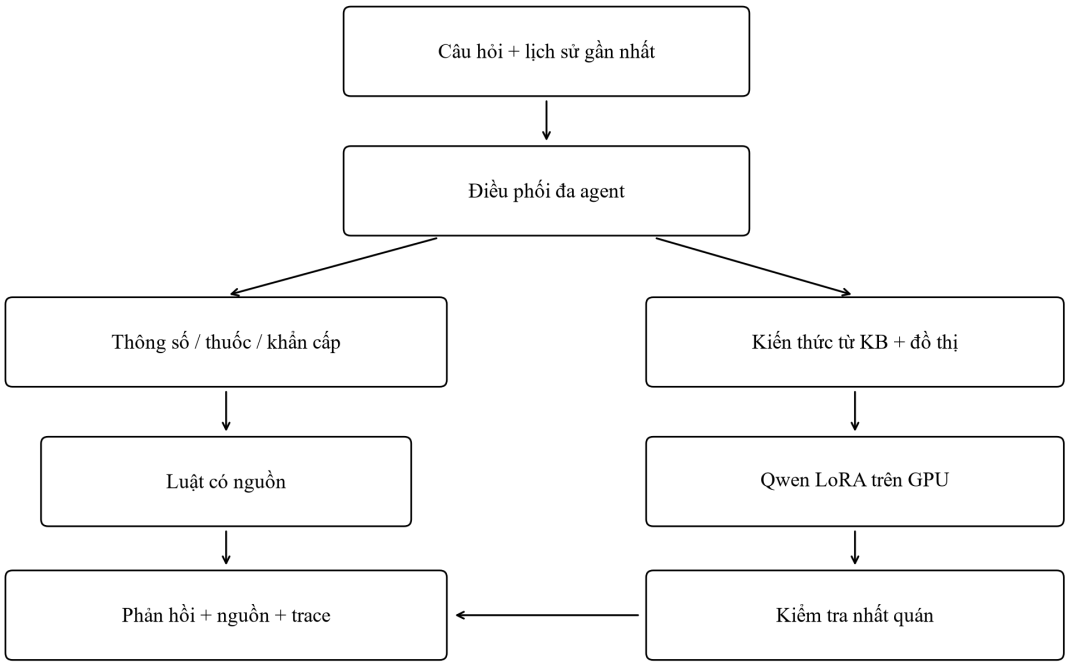
Trên nhóm kiến thức, checkpoint LoRA bám sát các đoạn KB hơn: câu hỏi chia bữa ăn không còn tự thêm số gram; câu hỏi về carbohydrate không còn suy diễn nguyên nhân bệnh ngoài tài liệu. Tuy nhiên, phần lớn phản hồi gần với văn bản KB. Kết quả chủ yếu cho thấy khả năng tuân thủ ngữ cảnh và định dạng, chưa chứng minh suy luận y khoa mới.

Ở nhóm hội thoại, mô hình thuần vẫn có hạn chế: lời bày tỏ thân thiện bị trả lời cứng và kèm mã nguồn không tồn tại; câu thiếu đơn vị HbA1c và câu hỏi tiếp nối chưa được làm rõ đầy đủ. Do đó bản ứng dụng không dùng trực tiếp đầu ra Qwen cho các trường hợp này, mà giữ định tuyến hội thoại và luật kiểm tra thông số. Loss validation rất thấp cần được đọc cùng thực tế rằng train và validation dùng chung đoạn nguồn và nhiều câu trả lời đích. Một nghiên cứu tiếp theo cần tập nguồn độc lập, cách diễn đạt đa dạng hơn và đánh giá chuyên gia.

7.4. Phối hợp đa agent khi trả lời

Điều phối xác định loại yêu cầu, truy xuất đoạn KB và gửi thông điệp đến agent ngôn ngữ cục bộ khi phù hợp. Agent kiểm chứng đối chiếu mã trích dẫn, số liệu và một số biểu thức không được phép trước khi chuyển câu trả lời ra giao diện. Nếu tải mô hình thất bại hoặc bản sinh không đạt kiểm tra, hệ thống trả về nội dung KB và ghi nguyên nhân trong trace.

Câu chứa thông số, câu về thuốc và tình huống khẩn cấp được ưu tiên xử lý bằng luật có nguồn. Qwen không được tự quyết định liều thuốc hay xác nhận bệnh. Bộ kiểm chứng hiện tại



Hình 7.2: Luồng xử lý tại máy cá nhân; phản hồi không đạt kiểm tra quay về nội dung KB.

là bộ lọc nhất quán, chưa kiểm tra được mọi sai lệch ngữ nghĩa. Lịch sử gần nhất hỗ trợ diễn đạt nối tiếp; lịch sử gửi từ trình duyệt không phải bộ nhớ bền vững giữa các phiên.

7.5. Tái lập và vận hành

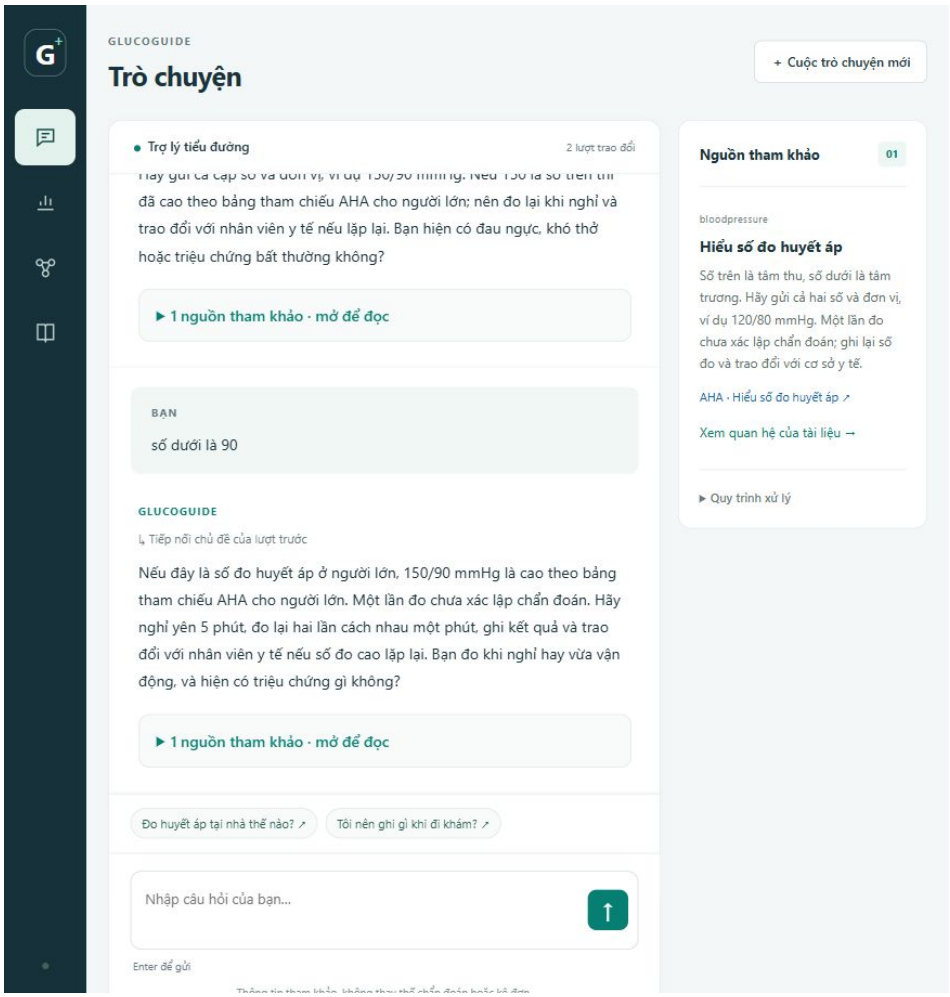
Chạy `experiments/local_qwen/train.py` bằng môi trường `.venv-llm` để tạo checkpoint, log loss và phản hồi kiểm thử. Adapter dùng để chạy được đóng gói tại `models/qwen_adapter`; checkpoint huấn luyện gốc nằm tại `.local-training/qwen-lora/best`. Mô hình nền và cache được lưu ngoài Git vì dung lượng lớn. Sau khi có đủ tệp, chế độ suy luận đặt biến offline để không tải tài nguyên từ mạng.

Khởi động bằng `run-local-qwen.ps1`, giữ cửa sổ tiến trình hoạt động và mở:

Demo Qwen cục bộ

`http://localhost:8766`

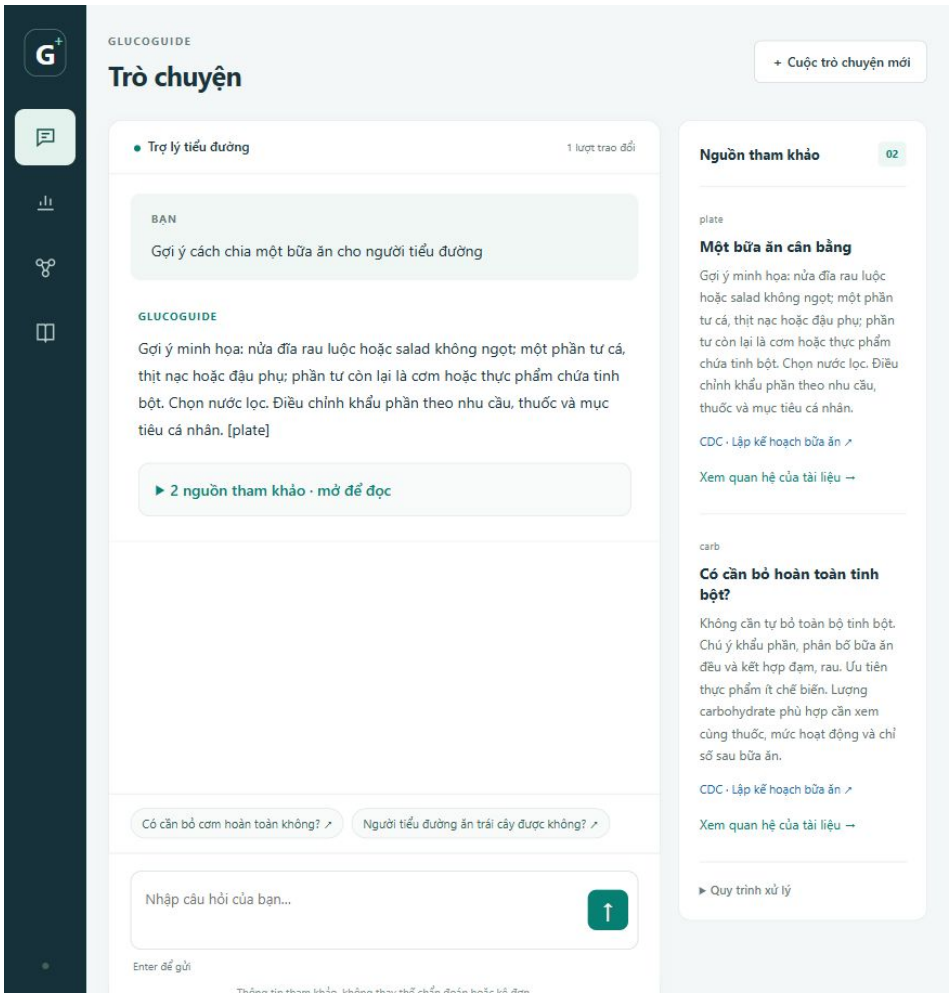
Địa chỉ này chỉ dùng trên máy đang chạy dịch vụ. Neo4j cục bộ phục vụ đồ thị; chức năng hội thoại dựa trên KB vẫn có cơ chế dự phòng khi không kết nối được đồ thị.



Hình 7.3: Kiểm tra hai lượt trên web local: hệ thống ghép thông tin bổ sung thành cặp số 150/90. Trường hợp này do luật hội thoại xử lý, không phải đầu ra tự do của Qwen.

7.5.1. Kiểm thử tích hợp trên web local

Tám kịch bản qua HTTP đã chạy thành công: chia bữa ăn và định nghĩa tiểu đường dùng Qwen LoRA; chào hỏi, huyết áp, bổ sung số dưới, thiếu đơn vị, yêu cầu liều thuốc và bất tỉnh dùng luật. Mã phản hồi ghi rõ thành phần tạo câu trả lời. Nhật ký tại `results/local_qwen/runtime_checks.json` lưu yêu cầu, phản hồi, thông điệp giữa các agent và thời gian đo. Các kiểm tra bổ sung gồm 33 tình huống chatbot và 7 điều kiện của bộ kiểm chứng/MessageBus. Đây là tập kiểm thử chức năng hữu hạn, không phải chứng nhận đúng với mọi cách hỏi.



Hình 7.4: Phản hồi Qwen LoRA trên web local sau huấn luyện, kèm các đoạn nguồn truy xuất.

Chương 8

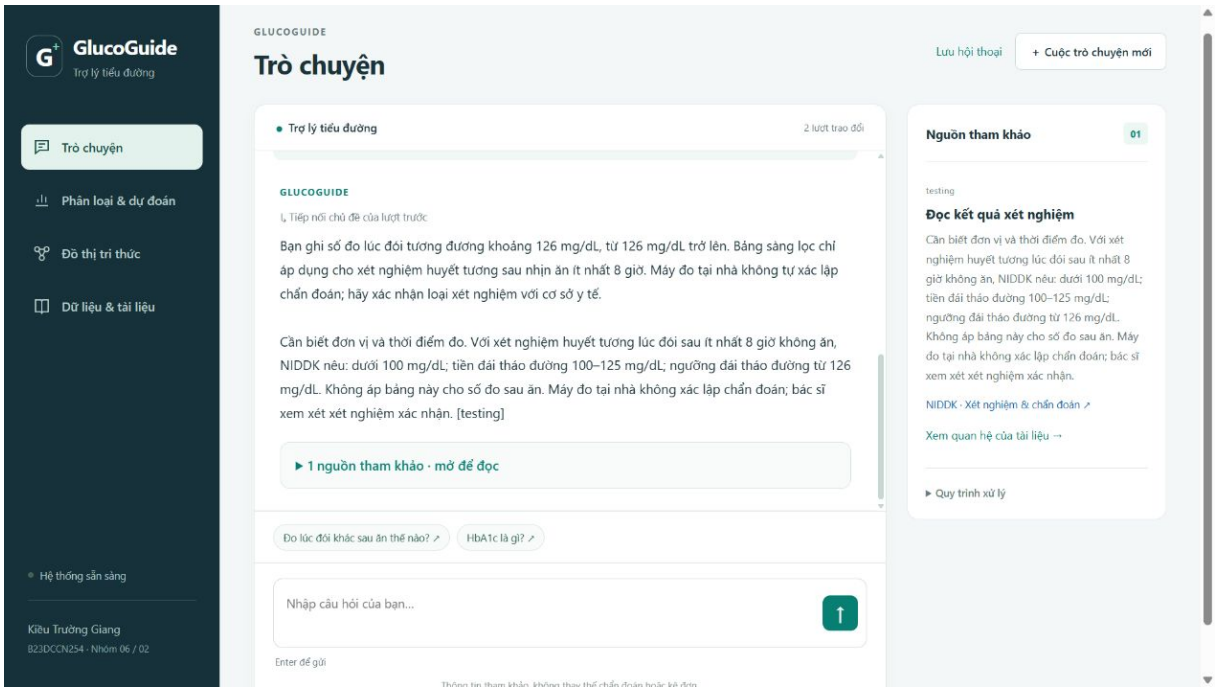
Giao diện và kịch bản sử dụng

8.1. Thiết kế giao diện và cách đọc kết quả

Giao diện có bốn khu vực: Trò chuyện, Phân loại & dự đoán, Đồ thị và Dữ liệu. Mỗi khu vực tương ứng với một nhiệm vụ kiểm tra; khối nhật ký trong cột căn cứ phản ánh lượt đang được chọn. Các hình minh họa ghi lại giao diện và kết quả thực nghiệm trên ứng dụng.

8.1.1. Trợ lý kiến thức

Người dùng nhập câu hỏi hoặc chọn câu hỏi gợi ý. Ví dụ "HbA1c là gì?" được gửi đến POST /api/chat với nhiệm vụ kiến thức. Bộ truy xuất tìm tối đa ba đoạn phù hợp; agent đối chiếu phạm vi và agent phản hồi tổng hợp nội dung có mã tài liệu. Người xem cần mở liên kết nguồn và đối chiếu nhật ký, không chỉ đọc câu trả lời. Nếu không có bằng chứng đạt ngưỡng, phản hồi yêu cầu làm rõ. Giao diện khóa nút gửi trong thời gian chờ và hiển thị lỗi kết nối khi yêu cầu thất bại.



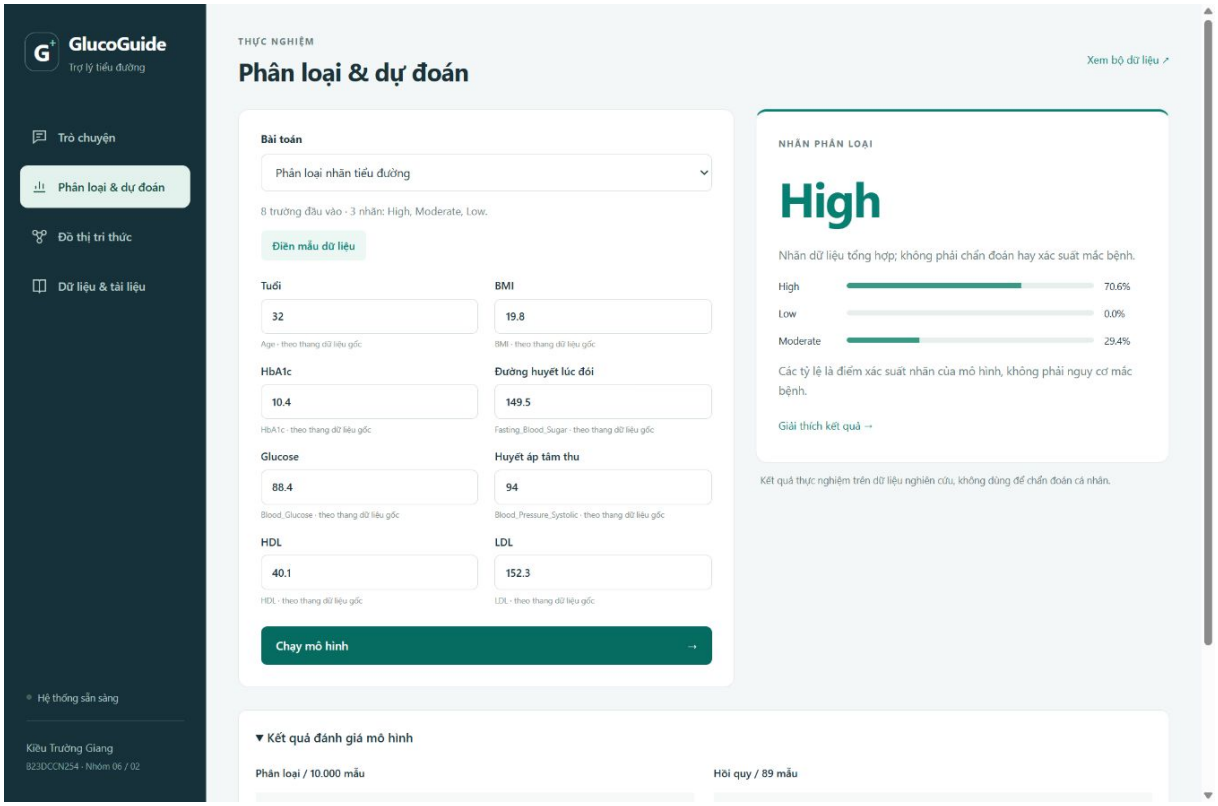
Hình 8.1: Hội thoại tiếp nối: bổ sung đơn vị và thời điểm đo cho số đường huyết đã nhập.

8.1.2. Thực nghiệm dữ liệu: phân loại

Mở giao diện thực nghiệm

`https://glucoguide-giang254.vercel.app/#models`

Chọn "Phân loại nhãn tiểu đường", bấm "Điền mẫu dữ liệu" rồi chạy mô hình MLP. Biểu mẫu gồm tám trường theo đúng schema của checkpoint. API kiểm tra dữ liệu trước khi pipeline điền thiếu, chuẩn hóa và suy luận. Đầu ra là một trong ba nhãn High, Moderate, Low của bộ dữ liệu tổng hợp. Nhãn này không phải xác suất hay chẩn đoán. Kết quả cần đọc cùng macro-F1 và recall lớp Low trong phần thực nghiệm, bởi tập dữ liệu mất cân bằng mạnh.



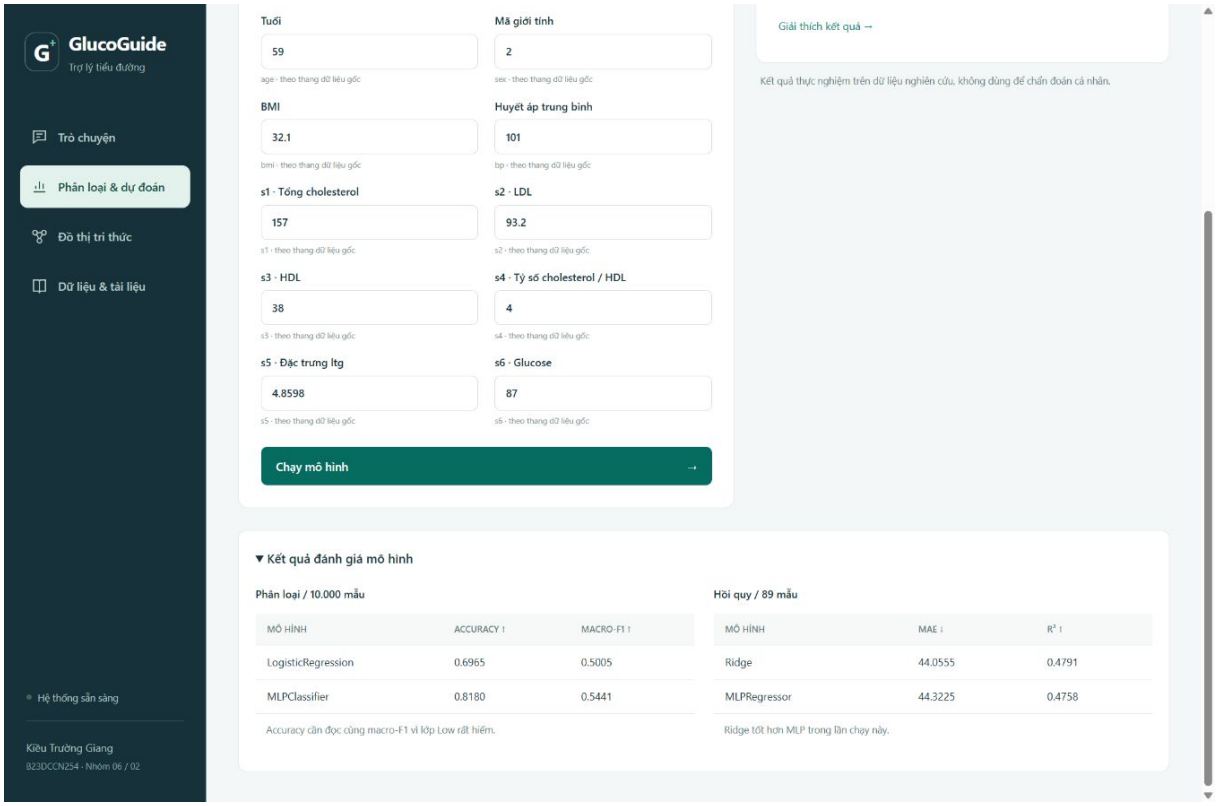
Hình 8.2: Màn hình phân loại: mẫu đầu vào và nhãn do checkpoint MLP trả về.

8.1.3. Thực nghiệm dữ liệu: hồi quy

Mở giao diện thực nghiệm

https://glucoguide-giang254.vercel.app/#models

Chuyển sang "Dự đoán điểm tiến triển" để tạo biểu mẫu mười trường. Bấm điền mẫu lại sau khi đổi bài toán; không tái sử dụng tám giá trị của mô hình phân loại. Các tên s1 đến s6 giữ nguyên theo dữ liệu nghiên cứu. Đầu ra là một số thực, được làm tròn hai chữ số trên giao diện; đây là điểm tiến triển sau một năm của bộ diabetes. Bảng kết quả công bố cả Ridge và MLP để thể hiện rằng mô hình sâu không mặc nhiên tốt hơn đối chứng.



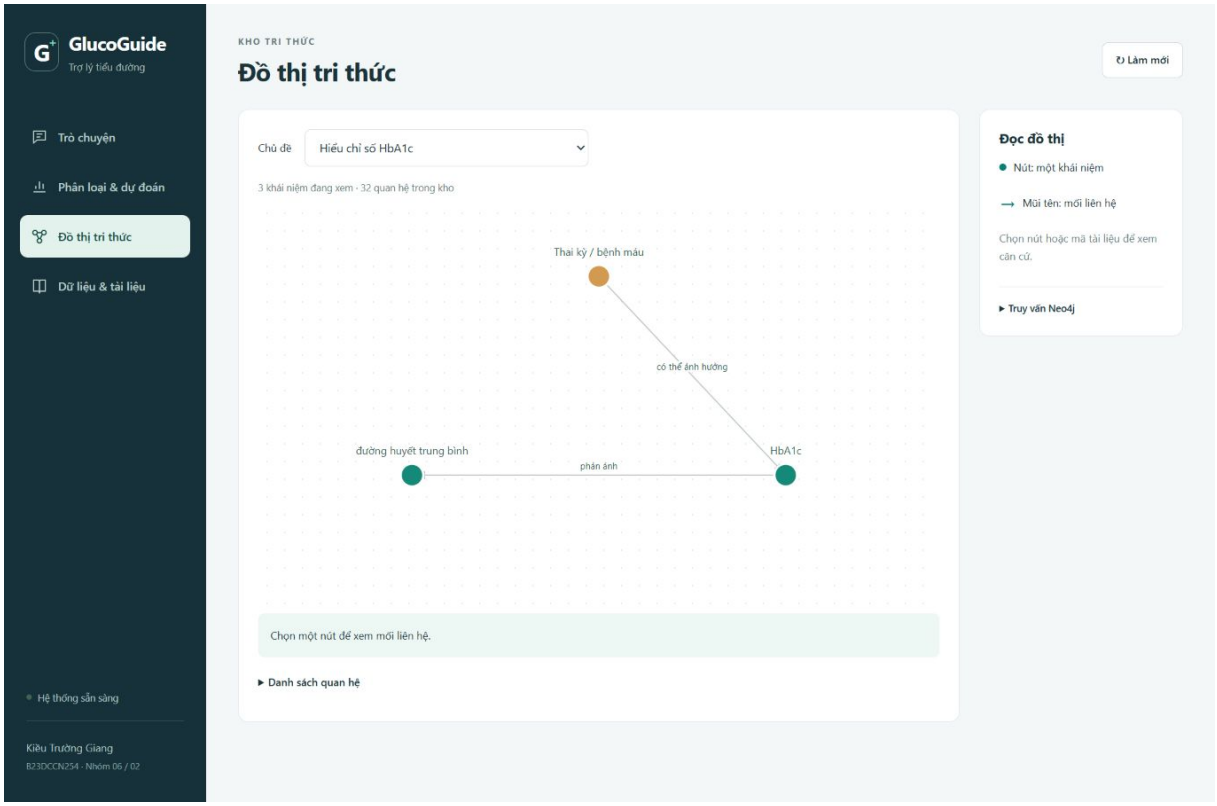
Hình 8.3: Màn hình hồi quy: biểu mẫu riêng và điểm tiến triển nghiên cứu.

8.1.4. Đồ thị tri thức và đối chiếu Neo4j

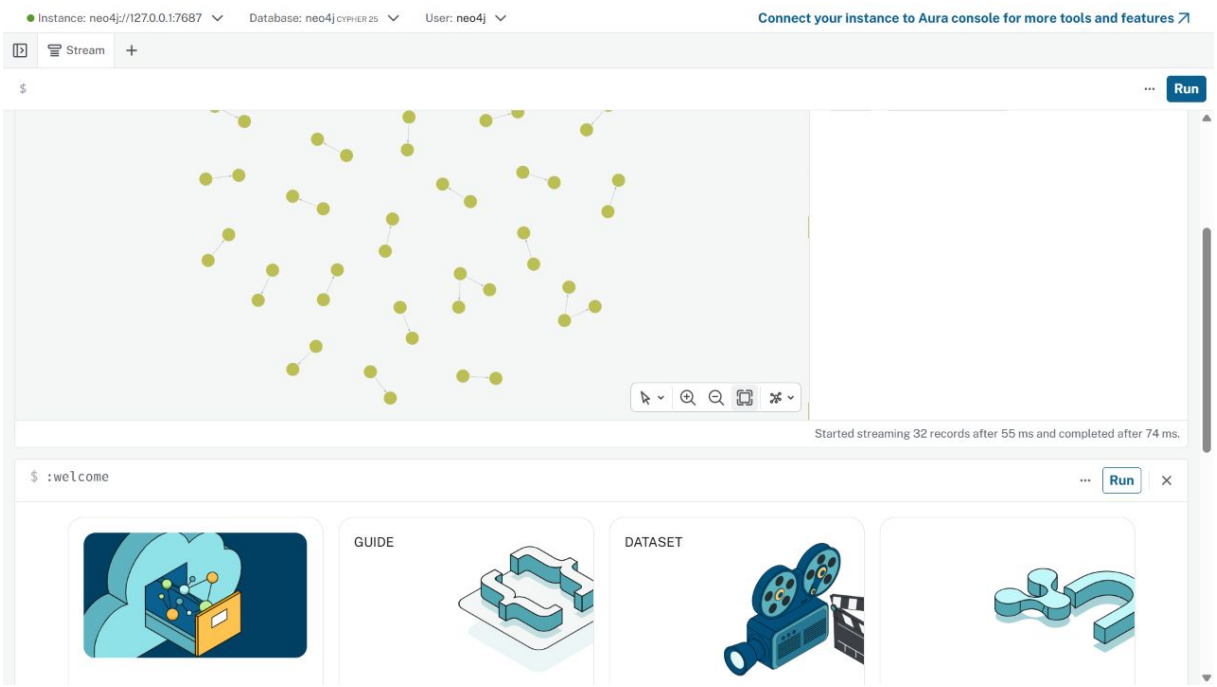
Mở giao diện thực nghiệm

https://glucoguide-giang254.vercel.app/#graph

Khu vực đồ thị gọi GET /api/graph để đọc các quan hệ thực. Chọn tài liệu a1c để thu nhỏ đồ thị và đọc tên các khái niệm. Bảng cạnh đi kèm thể hiện khái niệm nguồn, quan hệ, khái niệm đích và mã tài liệu. Khi Neo4j không kết nối được, giao diện thông báo lỗi thay vì dựng đồ thị giả. Bản công khai kết nối AuraDB Free. Nút Neo4j mở trang quản lý dành cho chủ tài khoản; người xem duyệt đồ thị trong web mà không cần cài phần mềm.



Hình 8.4: Đồ thị lọc theo tài liệu a1c, lấy từ Neo4j.



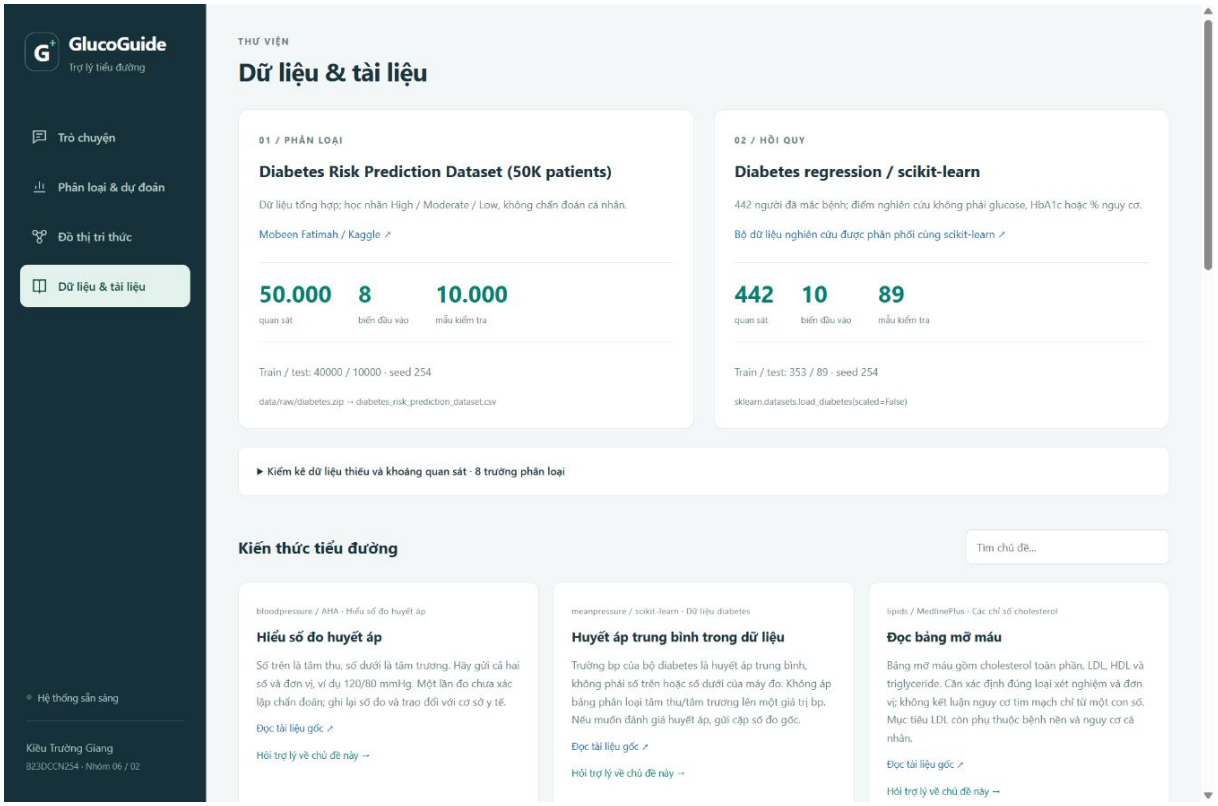
Hình 8.5: Đối chiếu quan hệ Concept trong Neo4j Browser ở môi trường cục bộ.

8.1.5. Dữ liệu và nguồn

Mở giao diện thực nghiệm
https://glucoguide-giang254.vercel.app/#data

Màn hình thứ tư công bố liên kết bộ dữ liệu, số dòng, số biến, số mẫu train/test và ý nghĩa nhãn. Bảng kiểm kê tám trường phân loại cho biết số giá trị thiếu cùng min, trung vị, max của bản chụp dữ liệu. Danh mục KB liệt kê chín nguồn đang được các đoạn văn sử dụng, kèm mã tài liệu. Bốn mục nguồn chưa được dùng trong registry không được tính vào chín nguồn này.

Nội dung được xuất bởi scripts/audit_data.py thành web/data_catalog.json đồng thời với results/data_audit.json. Khi thay dữ liệu, cần chạy lại bước kiểm kê để đồng bộ báo cáo và web. Kho tri thức hiện là các đoạn văn đã biên soạn; hệ thống chưa có chức năng tải sách hoặc tự thu thập website trong phiên chat.



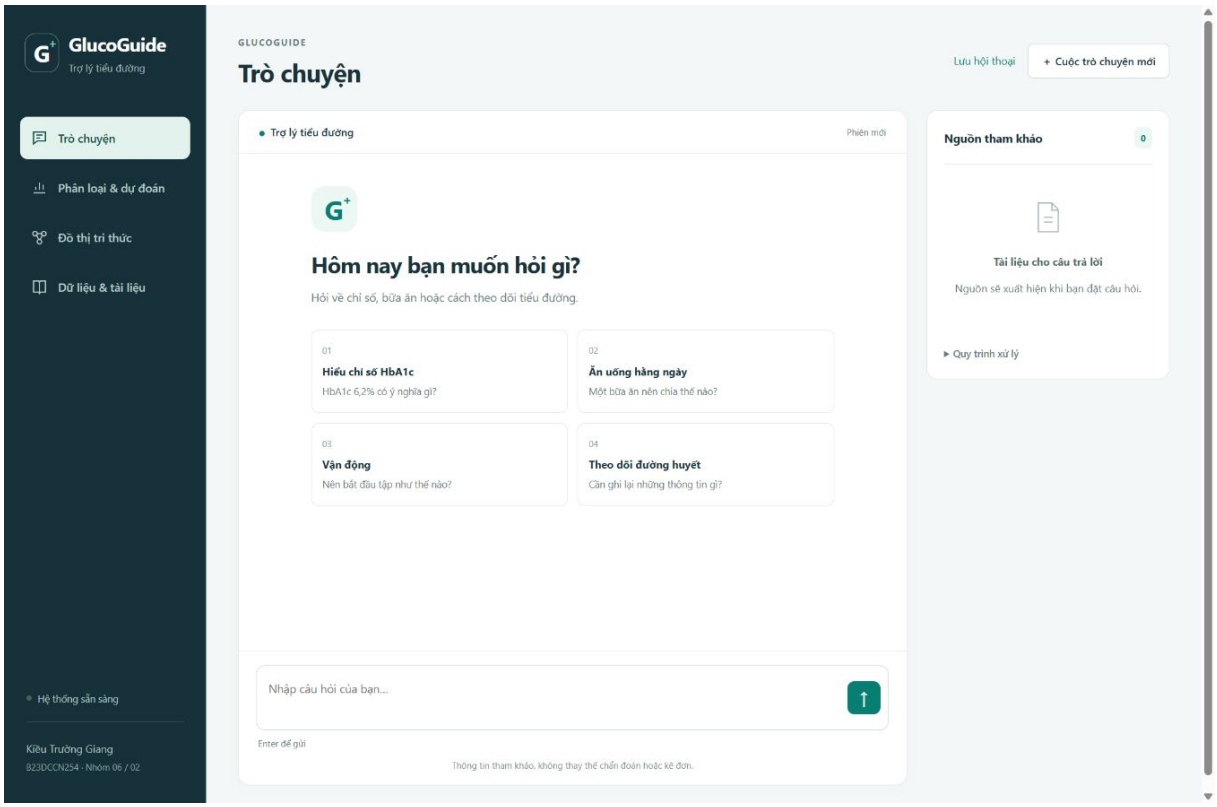
Hình 8.6: Màn hình công bố nguồn gốc và phạm vi hai bộ dữ liệu.

8.2. Thiết kế và vận hành chatbot tiểu đường

Chatbot kết hợp hội thoại có ngữ cảnh, tra cứu tài liệu và giải thích kết quả mô hình. Người dùng có thể hỏi tiếp về chủ đề đang trao đổi, đọc căn cứ ngay bên cạnh câu trả lời, hoặc chuyển kết quả thực nghiệm sang hội thoại để tìm hiểu ý nghĩa và giới hạn của đầu ra.

Giao diện sử dụng nền sáng, chữ không chân và màu xanh cho các thao tác chính. Thanh điều hướng bên trái phân chia bốn nhiệm vụ. Câu hỏi gợi ý nằm trong vùng hội thoại; nguồn đối chiếu ở cột bên phải, quy trình xử lý được thu gọn. Trên điện thoại, thanh điều hướng chuyển lên đầu trang và nội dung xếp theo một cột.

Truy cập trợ lý tiểu đường
https://glucoguide-giang254.vercel.app/#chat



Hình 8.7: Giao diện trợ lý tiểu đường với thanh điều hướng, vùng hội thoại và tài liệu đối chiếu.

8.2.1. Ngữ cảnh, phạm vi và cơ chế trả lời

API tiếp nhận history gồm tối đa 64 thông điệp, mỗi thông điệp tối đa 3.000 ký tự, role chỉ là user hoặc assistant. Khi câu hiện tại là câu hỏi tiếp nối ngắn, lớp luật tìm chủ đề có thể nhận diện trong những câu hỏi người dùng trước đó. Ví dụ, sau câu "HbA1c là gì?", câu "Vậy 7,1% thì sao?" được hiểu là tiếp tục về HbA1c. Các con số cũ không tự điền vào câu mới; hệ thống

không dựng hồ sơ lâm sàng đầy đủ từ lịch sử.

Lịch sử nằm trong bộ nhớ JavaScript của tab, không được ghi vào cơ sở dữ liệu. Nút cuộc trò chuyện mới xóa lịch sử ở giao diện. Tải lại trang cũng bắt đầu phiên mới. Nút nguồn tham khảo mở trích đoạn và liên kết gốc ngay dưới câu trả lời. Nút lưu hội thoại tạo tệp văn bản cục bộ theo thao tác người dùng. Máy chủ xử lý lịch sử trong từng yêu cầu; đây chưa phải hệ thống quản lý bệnh án hoặc bộ nhớ dài hạn.

Module conversation.py phân loại chủ đề và kiểm tra đơn vị bằng luật. Nếu có chủ đề rõ, nó chọn các mã tài liệu đã định nghĩa; trường hợp còn lại dùng TF-IDF. Vì vậy phần truy xuất là kết hợp luật định tuyến và tìm kiếm văn bản. "Hội thoại" trong trace là nhãn của module luật, không phải một agent tự chủ mới. Bốn đối tượng agent và MessageBus vẫn là các thành phần thực thi được mô tả trong kiến trúc.

Bộ phản hồi sử dụng các đoạn văn trong KB cùng phần giải thích được định dạng theo luật. Không có LLM được gọi, nên khả năng hiểu cách diễn đạt lạ, phủ định phức tạp hoặc nhiều ý đồng thời còn hạn chế. Đây là chatbot chuyên miền có phạm vi giới hạn, không tương đương hệ tư vấn y khoa tự động.

8.2.2. Kiểm tra chỉ số trước khi giải thích

HbA1c phải có đơn vị phần trăm; nếu thiếu đơn vị, chatbot hỏi lại thay vì tự coi là phần trăm. Đường huyết nhận mg/dL hoặc mmol/L; quy đổi xấp xỉ theo hệ số 18 được công bố trong câu trả lời. Số đo sau ăn hoặc không rõ thời điểm không bị tự áp bảng lúc đói. Khi phát hiện nội dung thai kỳ hoặc trẻ em trong ngữ cảnh được xét, hệ thống không dùng bảng người lớn để diễn giải cá nhân.

Các ngưỡng và lưu ý được rà soát theo NIDDK; hướng dẫn hạ đường huyết tham chiếu CDC. Luật về dấu hiệu khẩn cấp ưu tiên lời nhắc tìm trợ giúp y tế. Câu hỏi liều thuốc được chuyển về giải thích phạm vi và thông tin chuẩn bị cho bác sĩ. Luật nhận diện bằng từ khóa vẫn có thể bỏ sót cách diễn đạt chưa kiểm thử; kết quả đạt kiểm thử không phải chứng nhận an toàn lâm sàng.

8.2.3. Nối mô hình với hội thoại và so sánh đầu vào

Sau khi suy luận, người dùng có thể bấm "Đưa kết quả sang trò chuyện" để xem giải thích phạm vi và căn cứ. Thao tác giữ kết quả thực từ API, không dựng một dự đoán mới trong JavaScript. Người dùng cũng có thể đổi một trường và chạy lại để xem khác biệt so với lần chạy trước. Với mẫu hồi quy đã lưu, đổi BMI từ 32,1 thành 28 cho đầu ra từ 207,53 thành 179,64, chênh lệch khoảng -27,89 điểm trong lượt demo được kiểm tra. Đây là độ nhạy của mô hình trên đầu vào giả định; không suy ra hiệu quả điều trị hay mục tiêu giảm cân.

8.2.4. Tra cứu KB và sử dụng Neo4j

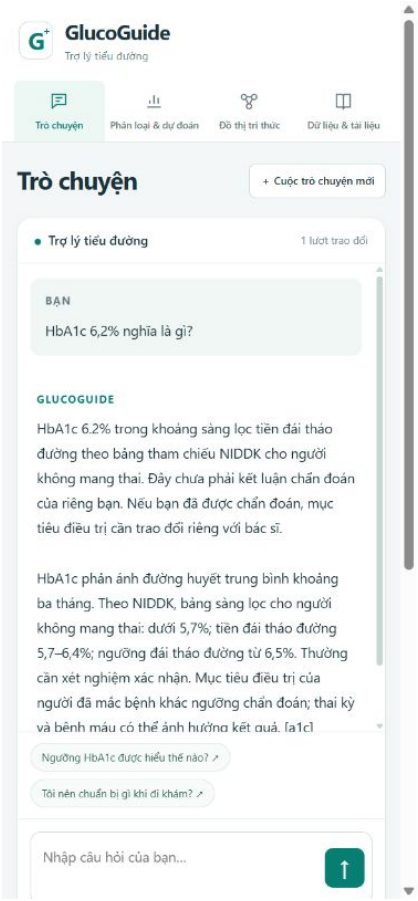
Mục Nguồn & tài liệu có tra cứu không dấu trên 22 đoạn kiến thức. Mỗi kết quả có nội dung, nguồn gốc và nút hỏi trợ lý. GET /api/knowledge trả các đoạn văn và thông tin nguồn; GET /api/status kiểm tra kết nối Neo4j và số lượng nút, cạnh.

Neo4j có bản cục bộ để phát triển và AuraDB Free cho demo công khai. Khi trạng thái kết nối thành công, người dùng vào Bản đồ tri thức, chọn HbA1c, bấm nút hoặc mã tài liệu để đọc căn cứ. Đồ thị có 60 khái niệm và 32 quan hệ. Tài liệu classification_scope có văn bản nhưng chưa có bộ ba; chọn tài liệu này trả về không có cạnh thay vì hiển thị các cạnh không liên quan. Khi dịch vụ tắt, chạy start-neo4j.ps1 từ thư mục project. Muốn dùng Neo4j Browser, mở localhost:7474/browser và dùng tài khoản trong cấu hình cục bộ; không đưa mật khẩu vào báo cáo hoặc GitHub.

8.2.5. Kiểm thử bổ sung và thiết bị

Tệp scripts/test_chatbot.py kiểm tra 29 tình huống hội thoại và 4 điều kiện API: lời chào, HbA1c, tiếp nối một và nhiều lượt, thiếu đơn vị, lúc đói, sau ăn, hạ đường huyết, khẩn cấp, câu hỏi kiến thức, liều thuốc, thai kỳ, ăn uống, ngoài miền và tách ngữ cảnh giữa yêu cầu. Bốn điều kiện API kiểm tra role không hợp lệ, lịch sử vượt giới hạn, tìm kiếm không dấu và trạng thái Neo4j. Cả 33 kiểm tra đạt; 8 kịch bản tích hợp trước đó cũng được chạy lại và đạt. Kết quả lưu tại results/chatbot_scenarios.json và results/api_scenarios.json.

Kiểm tra thủ công trên web bao gồm bấm nguồn sang đồ thị, chọn nút, tài liệu không có cạnh, phân loại, hồi quy, thay đổi đầu vào, chuyển kết quả sang chat, tìm kiếm không dấu và xóa phiên. Bố cục được kiểm tra tại viewport desktop 1366 px và điện thoại 390 px; trang chat không bị tràn ngang ở kích thước điện thoại kiểm tra. Chưa kiểm thử toàn bộ trình duyệt hay đánh giá trải nghiệm với người dùng thật.

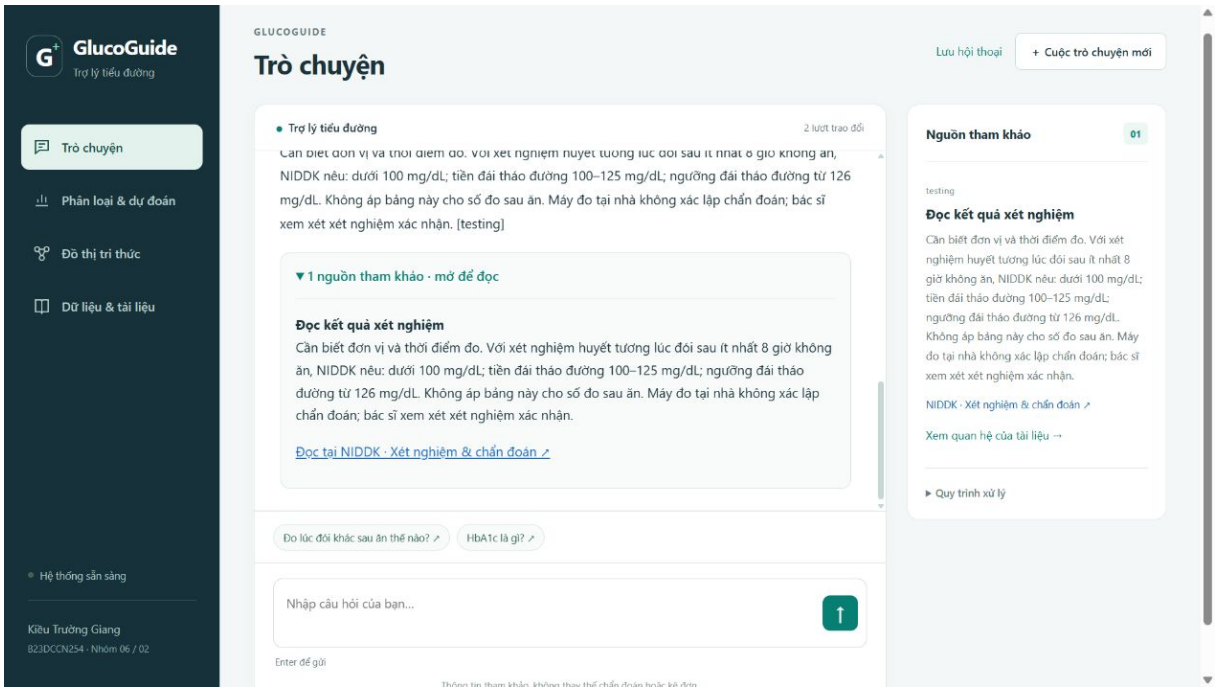


Hình 8.8: Bố cục điện thoại: điều hướng hai hàng và hội thoại một cột.

8.2.6. Hội thoại tiếp nối và đối chiếu nhiều chỉ số

Lớp hội thoại nhận tối đa 64 thông điệp trong phiên. Khi người dùng hỏi "đường huyết 7" rồi bổ sung "mmol/L, lúc đói", hệ thống ghép phần thông tin làm rõ với câu hỏi đang xét, công bố đơn vị và điều kiện áp dụng. Khi người dùng đưa một số đo mới, giá trị mới được xét riêng, không tự sao chép đơn vị từ số đo cũ. Với câu chứa cả HbA1c và đường huyết, mỗi chỉ số được đối chiếu theo loại xét nghiệm tương ứng, sau đó tổng hợp thành một phản hồi.

Nút nguồn dưới từng câu trả lời mở trực tiếp trích đoạn cùng liên kết đến tài liệu gốc. Nhờ đó người xem có thể kiểm tra căn cứ ngay cả trên màn hình hẹp. Bản công khai tổng hợp bằng luật và tài liệu. Nhánh local bổ sung Qwen LoRA với bước kiểm tra nhất quán; kết quả huấn luyện và giới hạn được trình bày trong chương riêng. Các câu nhiều ý, phủ định hoặc thay đổi chủ thể vẫn cần đánh giá thêm.



Hình 8.9: Mở trích đoạn và liên kết nguồn ngay bên dưới câu trả lời.

Tài liệu tham khảo

[1] Kiều Trường Giang, Tiểu luận 02, nhóm 06–02, báo cáo học phần.

[2] Kiều Trường Giang, Tiểu luận 03, B23DCCN254, báo cáo và thực nghiệm học phần.

[3] Phạm Mai Linh, Tiểu luận 01, nhóm 06–03, báo cáo học phần.

[4] Nguyễn Tự Kiên, Tiểu luận final CT_07 và Project01 CT_07, báo cáo học phần.

[5] Bùi Văn Lâm, Tiểu luận final CT_03 và Project01 CT_03, mã 477, báo cáo học phần.

[6] E. J. Hu và cộng sự, LoRA: Low-Rank Adaptation of Large Language Models, 2021. https://arxiv.org/abs/2106.09685.

[7] Qwen Team, Qwen3 1.7B, model card và hướng dẫn suy luận. https://huggingface.co/Qwen/Qwen3-1.7B.

[8] T. Kipf và M. Welling, Semi-Supervised Classification with Graph Convolutional Networks, ICLR 2017. https://arxiv.org/abs/1609.02907.

[9] W. Hamilton, R. Ying và J. Leskovec, Inductive Representation Learning on Large Graphs, 2017. https://arxiv.org/abs/1706.02216.

[10] P. Velickovic và cộng sự, Graph Attention Networks, ICLR 2018. https://arxiv.org/abs/1710.10903.

[11] M. Schlichtkrull và cộng sự, Modeling Relational Data with Graph Convolutional Networks, 2017. https://arxiv.org/abs/1703.06103.

[12] Scikit-learn, tài liệu load_diabetes. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html.

[13] Mobeen Fatimah, Diabetes Risk Prediction Dataset 50K Patients. https://www.kaggle.com/datasets/mobeenfatimah/diabetes-risk-prediction-dataset-50k-patients.

[14] NIDDK, Diabetes Tests and Diagnosis. https://www.niddk.nih.gov/health-information/diabetes/overview/tests-diagnosis.

[15] Danh mục nguồn tri thức của project được lưu tại data/knowledge.json; mỗi đoạn văn có mã tài liệu, mã nguồn và các bộ ba có căn cứ.

Phụ lục A

Mã nguồn tái lập

A.1. scripts/ingest_graph.py

```
from pathlib import Path
import json,os,sys
from neo4j import GraphDatabase
root=Path(__file__).resolve().parents[1]
sys.path.insert(0,str(root))
from app.settings import database
env=os.environ
kb=json.loads((root/'data/knowledge.json').read_text(encoding='utf-8'))
rows=[dict(source=t[0],label=t[1],target=t[2],document=d['id'],evidence=d['text']) for d in
 ↪  kb['documents'] for t in d.get('triples',[])]
constraint='CREATE CONSTRAINT concept_name IF NOT EXISTS FOR (c:Concept) REQUIRE c.name IS UNIQUE'
ingest='UNWIND $rows AS row MERGE (a:Concept {name:row.source}) MERGE (b:Concept {name:row.target})
 ↪  MERGE (a)-[r:RELATED_TO {label:row.label,document:row.document}]->(b) SET r.evidence=row.evidence'
if '--https' in sys.argv:
 import httpx
 from urllib.parse import urlparse,quote
 endpoint='https://'+urlparse(env['NEO4J_URI']).hostname+'/db/'+quote(database(),safe='')+'/query/v2'
 with httpx.Client(auth=(env['NEO4J_USER'],env['NEO4J_PASSWORD']),timeout=30) as client:
  for statement,parameters in [(constraint,{}),(ingest,{'rows':rows}),('MATCH (n:Concept) RETURN
   ↪  count(n) AS nodes',{})]:
   response=client.post(endpoint,json={'statement':statement,'parameters':parameters})
   response.raise_for_status();result=response.json()
   if result.get('errors'):raise RuntimeError(result['errors'])
  print(result['data'])
else:
 with GraphDatabase.driver(env['NEO4J_URI'],auth=(env['NEO4J_USER'],env['NEO4J_PASSWORD']),connection_
  ↪  timeout=5,max_transaction_retry_time=5) as
  ↪  driver:
  driver.execute_query(constraint,database_=database())
  driver.execute_query(ingest,rows=rows,database_=database())
  print(driver.execute_query('MATCH (n:Concept) RETURN count(n) AS
   ↪  nodes',database_=database()).records)
(root/'results/graph_import.json').write_text(json.dumps({'documents':len(kb['documents']),'relations'
 ↪  :len(rows),'storage':'Neo4j'}))
```

A.2. scripts/train_models.py

```
"""Train reproducible MLP classifier and regression baseline on distinct datasets."""
from pathlib import Path
import json, zipfile, warnings
import numpy as np
import pandas as pd
from sklearn.datasets import load_diabetes
from sklearn.model_selection import train_test_split
```

```
from sklearn.pipeline import make_pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.neural_network import MLPClassifier, MLPRegressor
from sklearn.linear_model import LogisticRegression, Ridge
from sklearn.metrics import accuracy_score, f1_score, mean_absolute_error, r2_score
import joblib
ROOT=Path(__file__).resolve().parents[1]
source=ROOT/'data/raw/diabetes.zip'
with zipfile.ZipFile(source) as z:
 df=pd.read_csv(z.open(z.namelist()[0]))
features=['Age','BMI','HbA1c','Fasting_Blood_Sugar','Blood_Glucose','Blood_Pressure_Systolic','HDL','L
↪ DL']
X=df[features];y=df.Diabetes_Risk
tr,te=train_test_split(np.arange(len(df)),test_size=.2,stratify=y,random_state=254)
rows=[]
for name,est in
↪ [('LogisticRegression',LogisticRegression(max_iter=1000,class_weight='balanced')),('MLPClassifier'
↪ ,MLPClassifier(hidden_layer_sizes=(64,32,16),early_stopping=True,max_iter=150,random_state=254))]:
 model=make_pipeline(SimpleImputer(strategy='median'),StandardScaler(),est)
 model.fit(X.iloc[tr],y.iloc[tr]); pred=model.predict(X.iloc[te])
 rows.append(dict(task='classification',model=name,n_train=len(tr),n_test=len(te),accuracy=accuracy_sc
 ↪ ore(y.iloc[te],pred),macro_f1=f1_score(y.iloc[te],pred,average='macro')))
 joblib.dump(model,ROOT/'models'/f'{name}.joblib')
 if name.startswith('MLP'): pd.DataFrame({'row':te,'actual':y.iloc[te].values,'predicted':pred}).to_cs
 ↪ v(ROOT/'results/classification_predictions.csv',index=False)
d=load_diabetes(scaled=False)
tr,te=train_test_split(np.arange(len(d.target)),test_size=.2,random_state=254)
for name,est in [('Ridge',Ridge(alpha=10)),('MLPRegressor',MLPRegressor(hidden_layer_sizes=(64,32,16),
↪ max_iter=1000,early_stopping=True,random_state=254))]:
 model=make_pipeline(StandardScaler(),est);model.fit(d.data[tr],d.target[tr]);pred=model.predict(d.dat
 ↪ a[te])
 rows.append(dict(task='regression',model=name,n_train=len(tr),n_test=len(te),mae=mean_absolute_error(
 ↪ d.target[te],pred),r2=r2_score(d.target[te],pred)))
 joblib.dump(model,ROOT/'models'/f'{name}.joblib')
 if name.startswith('MLP'): pd.DataFrame({'row':te,'actual':d.target[te],'predicted':pred}).to_csv(ROO
 ↪ T/'results/regression_predictions.csv',index=False)
(ROOT/'results/model_metrics.json').write_text(json.dumps(rows,indent=2))
(ROOT/'models/schema.json').write_text(json.dumps({'classification':features,'regression':list(d.featu
↪ re_names),'seed':254,'classification_scope':'synthetic dataset
↪ labels','regression_scope':'research progression score, not glucose or personal disease
↪ probability'},indent=2))
print(json.dumps(rows,indent=2))
```

A.3. scripts/train_policy.py

```
from pathlib import Path
import json,numpy as np
root=Path(__file__).resolve().parents[1]
rng=np.random.default_rng(254);q=np.zeros((4,3));history=[]
# Explicit simulated workflow: missing evidence -> clarify; evidence -> cite;
# prediction plus evidence -> explain model and cite. Not a treatment policy.
for ep in range(3000):
 s=int(rng.integers(4));a=int(rng.integers(3)) if rng.random()<.2 else int(q[s].argmax())
 target=0 if s%2==0 else (2 if s==3 else 1)
```

```
 reward=1. if a==target else -1.
 q[s,a]+=.15*(reward-q[s,a]);history.append(reward)
payload={'seed':254,'episodes':3000,'q':q.tolist(),'actions':['Hỏi làm rõ','Trả lời có nguồn','Giải
↪ thích mô hình và dẫn nguồn'],'environment':'One-step simulated workflow, not clinical
↪ outcomes','last_300_reward':float(np.mean(history[-300:]))}
(root/'models/workflow_policy.json').write_text(json.dumps(payload,ensure_ascii=False,indent=2),encodi
↪ ng='utf-8')
print(payload['last_300_reward'])
```

A.4. app/agents.py

```
from dataclasses import dataclass,field
from typing import Callable,Any
@dataclass
class Message:
 sender:str
 receiver:str
 type:str
 content:Any
@dataclass
class Agent:
 name:str
 handler:Callable
 memory:dict=field(default_factory=dict)
 def receive(self,message,bus):
  self.memory['calls']=self.memory.get('calls',0)+1
  self.memory['last_request']=message.type
  return self.handler(message.content,bus)
class MessageBus:
 def __init__(self):self.agents={};self.trace=[]
 def register(self,agent):self.agents[agent.name]=agent
 def request(self,sender,receiver,content,kind='REQUEST'):
  self.trace.append(vars(Message(sender,receiver,kind, str(content) if isinstance(content,dict) and
  ↪ 'x' in content else content)))
  try:
   result=self.agents[receiver].receive(Message(sender,receiver,kind,content),self)
   self.trace.append(vars(Message(receiver,sender,'INFORM',result.tolist() if hasattr(result,'tolist')
   ↪ else result)))
   return result
  except Exception as exc:
   self.trace.append(vars(Message(receiver,sender,'FAILURE',type(exc).__name__)))
   raise
```

A.5. app/conversation.py

```
"""Conversation routing with bounded user-turn context and cited, deterministic responses."""
import re, unicodedata
from app.intent import predict_intent

def norm(s):
 return ''.join(c for c in unicodedata.normalize('NFD',s.lower().replace('đ','d')) if
 ↪ unicodedata.category(c)!='Mn')
```

```
TOPICS=[('meanpressure',['huyet ap trung binh','bien bp','truong
↪ bp'],['meanpressure']),('bloodpressure',['huyet ap','tam thu','tam
↪ truong','mmhg'],['bloodpressure']),('a1c',['hba1c','a1c'],['a1c']),('meal',['an gi','an uong','bua
↪ an','thuc don','com','tinh bot','dinh duong'],['plate','carb']),('fruit',['trai cay','hoa
↪ qua','nuoc ep'],['fruit','carb']),('activity',['van dong','the duc','di bo','tap luyen'],['activit
↪ y']),('medicine',['thuoc','insulin','metformin','lieu'],['medicine']),('symptoms',['trieu
↪ chung','khat nhieu','tieu nhieu','sut can'],['symptoms','testing']),('low',['ha duong','duong
↪ huyet thap','run tay','va mo hoi'],['low','urgent']),('testing',['duong huyet','glucose','xet
↪ nghiem'],['testing']),('monitor',['theo doi','ghi chep','nhat ky','do luc
↪ nao'],['monitor']),('model',['diem tien trien','hoi quy'],['model']),('diabetes',['tieu
↪ duong','dai thao duong'],['overview','testing']),('classification',['nhan high','nhan low','nhan
↪ moderate','phan loai','nhan tong hop'],['classification_scope'])]
FOLLOW={
 'bloodpressure':['Đo huyết áp tại nhà thế nào?','Tôi nên ghi gì khi đi khám?'],
 'a1c':['Ngưỡng HbA1c được hiểu thế nào?','Tôi nên chuẩn bị gì khi đi khám?'],
 'meal':['Có cần bỏ cơm hoàn toàn không?','Người tiểu đường ăn trái cây được không?'],
 'fruit':['Gợi ý cách chia một bữa ăn','Tôi nên theo dõi đường huyết thế nào?'],
 'testing':['Đo lúc đói khác sau ăn thế nào?','HbA1c là gì?'],
 'medicine':['Tôi nên ghi gì để trao đổi với bác sĩ?','Dấu hiệu hạ đường huyết là gì?'],
 'low':['Theo dõi để tránh hạ đường huyết thế nào?'],
 'activity':['Tôi nên theo dõi đường huyết thế nào?'],
 'monitor':['Gợi ý cách chia một bữa ăn','HbA1c là gì?'],
 'symptoms':['Tôi nên chuẩn bị gì khi đi khám?'],
 'classification':['Nhãn High có phải chẩn đoán không?'],
 'diabetes':['HbA1c là gì?','Tôi nên theo dõi đường huyết thế nào?'],
 'model':['Điểm tiến triển có phải đường huyết không?']}

def topic(q):
 for key,terms,ids in TOPICS:
  if any(re.search(r'(?<!\w)'+re.escape(t)+r'(?!\w)',norm(q)) for t in terms):return key,ids
 if re.search(r"\d|so duoi|so tren|thi sao|chi tiet|giai thich them",norm(q)):return None,[]
 learned=predict_intent(norm(q))
 if learned:
  return next((key,ids) for key,terms,ids in TOPICS if key==learned)
 return None,[]

def _route(question,history):
 q=norm(question); key,ids=topic(question);used=False; prior=''
 if any(t in q for t in ['lieu thuoc','lieu insulin','bao nhieu don vi','tang lieu','giam
 ↪ lieu']):key,ids='medicine',['medicine']
 # Only the most recent user question can supply a topic; never reuse old numeric values.
 previous=[h['content'] for h in history if h['role']=='user']
 if previous:
  prior=next((text for text in reversed(previous) if topic(text)[0]),previous[-1])
 if not key and prior and (len(q)<90 and any(t in q for t in ['vay','the con','chi so do','no la','co
 ↪ cao','bao nhieu','nghia la','nen lam','6.','7.','%','so duoi','so tren','con ','thi sao','co
 ↪ on'])):
  key,ids=topic(prior);used=bool(key)
 query=(key+' '+question) if used else question
 if used:query=prior+' '+question
 result={'topic':key or 'knowledge','ids':ids,'query':query,'context_used':used,'intro':'','override':
 ↪ None,'tone':'normal','suggestions':FOLLOW.get(key,['HbA1c là gì?','Gợi ý cách chia một bữa
 ↪ ăn','Tôi nên theo dõi đường huyết thế nào?'])}
 # Active emergency wording is separate from an educational question about symptoms.
 urgent=any(t in q for t in ['bat tinh','co giat','khong nuot duoc','kho tho','lu lan'])
 educational=any(t in q for t in ['la gi','dau hieu','neu ','khi nao','khong bi','khong co','khong kho
 ↪ tho'])
 if urgent and not educational:
```

```
 result.update(topic='urgent',ids=['urgent'],tone='urgent',intro='Tình huống bạn mô tả có thể cần trợ
  ↪ giúp y tế khẩn cấp. Đừng chờ câu trả lời tiếp theo trên chat.',suggestions=[]);return result
if re.fullmatch(r'(xin chao|chao|hello|hi|cam on|thank you)[!. ]*',q):
 result.update(override='Chào bạn. Tôi có thể cùng bạn tìm hiểu tiểu đường: giải thích HbA1c, cách ăn
  ↪ uống, theo dõi đường huyết và đọc ý nghĩa kết quả nghiên cứu. Bạn đang muốn hỏi về chỉ số hay
  ↪ sinh hoạt hằng ngày?',ids=[]);return result
if 'chuan bi' in q or 'ghi gi' in q:
 result.update(topic='monitor',ids=['monitor','medicine'],intro='Để buổi khám hữu ích hơn, hãy chuẩn
  ↪ bị phiếu xét nghiệm và ghi lại các thông tin sau.');return result
if key=='medicine':
 result['intro']='Tôi có thể giải thích nguyên tắc dùng thuốc, nhưng không chọn thuốc hoặc tính liều
  ↪ cho bạn.'
# Avoid assigning adult screening ranges during pregnancy or in children.
special=any(t in q+' '+norm(prior) for t in ['mang thai','thai ky','tre em','be nha','con toi'])
if special and key in ['a1c','testing','low']:
 result.update(intro='Trẻ em và thai kỳ cần cách đánh giá riêng. Tôi không áp bảng ngưỡng người lớn
  ↪ cho trường hợp này; hãy trao đổi với cơ sở đang theo
  ↪ dõi.',ids=['demographics','monitor']);return result
if key=='bloodpressure':
 result.update(ids=['bloodpressure'])
 if special:
  result['override']='Với trẻ em hoặc thai kỳ, cách đánh giá huyết áp cần theo bối cảnh riêng. Bạn
   ↪ cho biết tuổi hoặc tuần thai, cả hai số đo và triệu chứng hiện tại; liên hệ cơ sở đang theo dõi
   ↪ để được hướng dẫn.';return result
 pair=re.search(r'(\d{2,3})\s*[/\-]\s*(\d{2,3})',q)
 # A short follow-up can explicitly provide the missing lower number.
 if not pair and used and re.search(r'so duoi|tam truong',q):
  upper=re.search(r'huyet ap\s*(\d{2,3})',norm(prior))
  lower=re.search(r'(?:so duoi|tam truong)\s*(?:la\s*)?(\d{2,3})',q)
  if upper and lower:pair=(upper[1],lower[1])
 if pair:
  top,bottom=int(pair[1] if not isinstance(pair,tuple) else pair[0]),int(pair[2] if not
   ↪ isinstance(pair,tuple) else pair[1])
  if not (40<=top<=300 and 20<=bottom<=200 and top>bottom):
   result['override']='Bạn kiểm tra lại hai số và thứ tự trên/dưới trên máy đo nhé; cặp số này chưa
    ↪ hợp lý để diễn giải.';return result
  if top>=180 or bottom>=120:
   result.update(tone='urgent',override=f'Số đo {top}/{bottom} mmHg rất cao. Nếu có đau ngực, khó
    ↪ thở, yếu liệt, nhìn mờ hoặc khó nói, hãy gọi cấp cứu địa phương ngay. Nếu không có các triệu
    ↪ chứng đó, nghỉ yên, đo lại sau ít nhất một phút và liên hệ nhân viên y tế ngay nếu số đo vẫn
    ↪ rất cao. Không tự tăng liều thuốc.',suggestions=[]);return result
  band='cao theo bảng tham chiếu AHA cho người lớn' if top>=130 or bottom>=80 else ('tăng nhẹ ở số
   ↪ trên' if top>=120 else 'dưới ngưỡng tăng huyết áp theo bảng AHA')
  result['override']=f'Nếu đây là số đo huyết áp ở người lớn, {top}/{bottom} mmHg là {band}. Một lần
   ↪ đo chưa xác lập chẩn đoán. Hãy nghỉ yên 5 phút, đo lại hai lần cách nhau một phút, ghi kết quả
   ↪ và trao đổi với nhân viên y tế nếu số đo cao lặp lại. Bạn đo khi nghỉ hay vừa vận động, và hiện
   ↪ có triệu chứng gì không?';return result
 number=re.search(r'(?<!\w)(\d{2,3})(?!\w)',q)
 if number:
  v=int(number[1]);result['override']=f'Bạn nói huyết áp {v}: đây là số trên (tâm thu) hay số dưới
   ↪ (tâm trương)? Hãy gửi cả cặp số và đơn vị, ví dụ 150/90 mmHg. Nếu {v} là số trên thì '+('đã cao
   ↪ theo bảng tham chiếu AHA cho người lớn; nên đo lại khi nghỉ và trao đổi với nhân viên y tế nếu
   ↪ lặp lại.' if v>=130 else 'cần xem thêm số dưới và điều kiện đo để nhận xét.')+' Bạn hiện có đau
   ↪ ngực, khó thở hoặc triệu chứng bất thường không?';return result
 if any(t in q for t in ['do the nao','cach do','tai nha']):
  result['override']='Để đo huyết áp tại nhà: nghỉ yên 5 phút, ngồi tựa lưng, hai chân đặt trên sàn,
   ↪ tay đỡ ngang tim và không nói chuyện khi đo. Tránh hút thuốc, caffeine và vận động trong 30
   ↪ phút trước đo. Dùng vòng bít phù hợp, đo hai lần cách nhau một phút và ghi cả số trên/số dưới
   ↪ cùng thời điểm.';return result
```

```
  result['override']='Huyết áp có hai số: số trên là tâm thu, số dưới là tâm trương, thường ghi bằng
   ↪  mmHg. Bạn gửi cả cặp số (ví dụ 120/80), thời điểm đo và triệu chứng hiện tại để tôi giải thích
   ↪  đúng bối cảnh.';return result
 if key=='a1c':
  match=re.search(r'(?:hba1c|a1c)\s*(?:cua toi|la|=|:)?\s*(\d+(?:[.,]\d+)?)',q) or
   ↪  re.search(r'(\d+(?:[.,]\d+)?)\s*%',q)
  if match:
   value=float(match[1].replace(',','.'))
   if '%' not in q:
    result.update(override='Bạn xác nhận HbA1c này có đơn vị % không? Nếu phiếu ghi mmol/mol, cần diễn
     ↪  giải theo đơn vị đó; tôi chưa áp ngưỡng khi thiếu đơn vị.',ids=['a1c']);return result
   if not 2<=value<=25:
    result.update(override='Giá trị HbA1c này nằm ngoài miền mà bản demo xử lý. Bạn kiểm tra lại tên
     ↪  xét nghiệm, con số và đơn vị trên phiếu nhé.',ids=['a1c']);return result
   band='dưới ngưỡng tiền đái tháo đường' if value<5.7 else ('trong khoảng sàng lọc tiền đái tháo
    ↪  đường' if value<6.5 else 'đạt ngưỡng xét nghiệm dùng để chẩn đoán đái tháo đường')
   result['intro']=f'HbA1c {value:g}% {band} theo bảng tham chiếu NIDDK cho người không mang thai. Đây
    ↪  chưa phải kết luận chẩn đoán của riêng bạn. Nếu bạn đã được chẩn đoán, mục tiêu điều trị cần
    ↪  trao đổi riêng với bác sĩ.'
 if key in ['testing','low']:
  match=re.search(r'(\d+(?:[.,]\d+)?)\s*(mg\s*/?\s*dl|mmol\s*/?\s*l)',q)
  if match:
   value=float(match[1].replace(',','.'));mg=value*18 if 'mmol' in match[2] else value
   if mg<=0 or mg>1000:
    result.update(override='Bạn kiểm tra lại giá trị và đơn vị đường huyết trên phiếu. Con số này nằm
     ↪  ngoài miền xử lý của bản demo.',ids=['testing']);return result
   if mg<70:
    result.update(topic='low',ids=['low','urgent'],tone='urgent',intro=f'Số đo bạn nhập tương đương
     ↪  khoảng {mg:g} mg/dL, dưới mức 70 mg/dL mà CDC coi là thấp. Nếu đây là số đo hiện tại, cần xử
     ↪  trí ngay; nếu khó nuốt, lú lẫn hoặc bất tỉnh, nhờ người bên cạnh gọi cấp
     ↪  cứu.',suggestions=FOLLOW['low']);return result
   fasting=bool(re.search(r'\b(luc doi|nhin doi)\b',q)) and not any(t in q for t in ['khong
    ↪  doi','khong phai luc doi'])
   if fasting:
    band='dưới 100 mg/dL' if mg<100 else ('trong khoảng 100–125 mg/dL' if mg<126 else 'từ 126 mg/dL
     ↪  trở lên')
    result['intro']=f'Bạn ghi số đo lúc đói tương đương khoảng {mg:g} mg/dL, {band}. Bảng sàng lọc chỉ
     ↪  áp dụng cho xét nghiệm huyết tương sau nhịn ăn ít nhất 8 giờ. Máy đo tại nhà không tự xác lập
     ↪  chẩn đoán; hãy xác nhận loại xét nghiệm với cơ sở y tế.'
   else:result['intro']='Bạn đo lúc đói, sau ăn hay ngẫu nhiên, và đo tại nhà hay xét nghiệm ở cơ sở y
    ↪  tế? Tôi chưa áp ngưỡng lúc đói cho số đo thiếu bối cảnh.'
  elif re.search(r'\d',q):result['intro']='Bạn bổ sung đơn vị mg/dL hoặc mmol/L và thời điểm đo nhé.
   ↪  Một con số chưa đủ để diễn giải đường huyết.'
 return result


def contextual_route(question, history):
 """Resolve explicitly supplied follow-up fields, without silently inventing values."""
 q=norm(question)
 if q.strip(' .!?') in ['toi yeu ban','yeu ban','cam on ban','ban de thuong qua']:
  return {'topic':'social','ids':[],'query':question,'context_used':False,'intro':'','override':'Cảm
   ↪  ơn bạn đã quý mến. Tôi luôn sẵn sàng giúp bạn tìm hiểu tiểu đường và các chỉ số. Bạn muốn trao
   ↪  đổi điều gì tiếp theo?','tone':'normal','suggestions':['Tiểu đường là gì?','HbA1c là gì?']}
 users=[h['content'] for h in history if h['role']=='user']
 # Retain only the active topic; a new explicit topic starts a new context.
 anchor=None
 for i in range(len(users)-1,-1,-1):
  if topic(users[i])[0]:anchor=i;break
 current=topic(question)[0]
```

```
 if anchor is not None:
  old_topic=topic(users[anchor])[0]
  short=bool(re.fullmatch(r'[\d.,% /a-z]+',q)) and len(q)<45
  clarify=any(t in q for t in ['mmol','mg/dl','phan tram','luc doi','sau an','so duoi','so tren','noi
   ↪  ro','chi tiet','giai thich them','toi nen lam gi'])
  if not current and (short or clarify):
   recent=' '.join(users[anchor:])
   # Unit-only clarification attaches to the last measurement; a new number replaces it.
   if old_topic in ['a1c','testing'] and not re.search(r'\d',q) and any(t in q for t in
    ↪  ['mmol','mg/dl','%','phan tram','luc doi','sau an']):
    enriched=recent+' '+question.replace('phần trăm','%')
    result=_route(enriched,history);result['context_used']=True;return result
   if old_topic in ['a1c','testing'] and re.search(r'\d',q):
    result=_route(('HbA1c ' if old_topic=='a1c' else 'đường huyết
     ↪  ')+question,history);result['context_used']=True;return result
   if any(t in q for t in ['noi ro','chi tiet','giai thich them','toi nen lam gi']):
    result=_route(users[anchor],history);result['context_used']=True
    extra={
     'a1c':'Bước tiếp theo: kiểm tra đúng tên xét nghiệm và đơn vị trên phiếu, mang các kết quả trước
      ↪  đây khi đi khám, và trao đổi việc xét nghiệm xác nhận nếu kết quả cao. HbA1c phản ánh nhiều
      ↪  tuần, nên không đánh giá thay đổi chỉ sau một bữa ăn. Bạn đã được chẩn đoán tiểu đường trước
      ↪  đây hay đang kiểm tra lần đầu?',
     'testing':'Để đọc kết quả sát hơn, cần biết đơn vị, lúc đói hay sau ăn, thời gian nhịn ăn và đây
      ↪  là máy đo tại nhà hay xét nghiệm tại cơ sở y tế. Bạn đã có thông tin nào trong số này?',
     'bloodpressure':'Bạn nên ghi cả hai số đo, giờ đo, có vừa vận động hay không, thuốc đang dùng và
      ↪  triệu chứng. Nghỉ yên trước khi đo lại; kết quả cao lặp lại cần trao đổi với nhân viên y tế.
      ↪  Bạn đã đo lại lần thứ hai chưa?',
     'meal':'Bạn có thể bắt đầu từ một bữa quen thuộc: chia rau, đạm và phần tinh bột theo gợi ý trong
      ↪  nguồn. Không tự bỏ hết tinh bột, đặc biệt khi dùng thuốc dễ gây hạ đường huyết. Bạn thường ăn
      ↪  gì ở bữa chính và muốn điều chỉnh bữa nào?'}
    if old_topic in extra:
     result['override']=(result['override'] or result['intro'] or '')+'\n\n'+extra[old_topic]
    return result
 return _route(question,history)


def route(question, history):
 # Parse independent measurements separately, so one topic cannot hide the other.
 q=norm(question)
 if 'hba1c' in q and any(t in q for t in ['duong huyet','glucose']):
  a=re.search(r'(?:hba1c|a1c)\s*(?:la|:|=)?\s*\d+(?:[.,]\d+)?\s*%?',q)
  g=re.search(r'(?:duong huyet|glucose)\s*(?:luc doi|sau
   ↪  an)?\s*(?:la|:|=)?\s*\d+(?:[.,]\d+)?\s*(?:mg/dl|mmol/l)?',q)
  if a and g:
   plans=[contextual_route(x.group(),history) for x in [a,g]]
   # Special populations and urgent flags must still govern the whole question.
   guard=_route(question,history)
   if guard['tone']=='urgent' or any(t in q for t in ['mang thai','thai ky','tre em','con
    ↪  toi']):return guard
   result=plans[0].copy();result['ids']=list(dict.fromkeys(i for p in plans for i in p['ids']))
   result['override']='Đối chiếu từng chỉ số bạn cung cấp:\n\n'+'\n\n'.join((p['override'] or
    ↪  p['intro']) for p in plans)+'\n\nHai phép đo phản ánh những khoảng thời gian khác nhau. Hãy
    ↪  mang phiếu xét nghiệm để bác sĩ đối chiếu và xác nhận; không quy đổi điểm mô hình nghiên cứu
    ↪  thành chẩn đoán.'
   if any(p['tone']=='urgent' for p in plans):result.update(tone='urgent',suggestions=[])
   return result
 return contextual_route(question,history)
```

A.6. app/main.py

```
import json, os, math, re, unicodedata
from pathlib import Path
import numpy as np
import pandas as pd
import joblib
from fastapi import FastAPI, HTTPException
from fastapi.responses import FileResponse
from fastapi.staticfiles import StaticFiles
from pydantic import BaseModel, Field
from neo4j import GraphDatabase
from app.agents import Agent, MessageBus
from app.conversation import route
from app import local_llm
from app.settings import database, browser_url
from typing import Literal
from sklearn.feature_extraction.text import TfidfVectorizer
ROOT=Path(__file__).resolve().parents[1]
for line in (ROOT/'.env').read_text().splitlines() if (ROOT/'.env').exists() else []:
 if '=' in line:
  k,v=line.split('=',1);os.environ.setdefault(k,v)
kb=json.loads((ROOT/'data/knowledge.json').read_text(encoding='utf-8'))
docs=kb['documents']
vec=TfidfVectorizer(strip_accents='unicode',ngram_range=(1,2))
mat=vec.fit_transform([d['title']+' '+' '.join(d['terms'])+' '+d['text'] for d in docs])
schema=json.loads((ROOT/'models/schema.json').read_text())
models={k:joblib.load(ROOT/'models'/f'{v}.joblib') for k,v in
 ↪  [('classification','MLPClassifier'),('regression','MLPRegressor')]}
app=FastAPI(title='GlucoGuide • Giang KT')
app.mount('/assets',StaticFiles(directory=ROOT/'web'),name='assets')
class Turn(BaseModel):
 role:Literal["user","assistant"]
 content:str=Field(max_length=3000)

class Request(BaseModel):
 question:str=Field(default='',max_length=3000)
 task:str='knowledge'
 values:dict=Field(default_factory=dict)
 history:list[Turn]=Field(default_factory=list,max_length=64)
def graph_driver():
 return GraphDatabase.driver(os.environ.get('NEO4J_URI','bolt://127.0.0.1:7687'),auth=(os.environ.get(
  ↪  'NEO4J_USER','neo4j'),os.environ.get('NEO4J_PASSWORD','')),connection_timeout=3,connection_acquis
  ↪  ition_timeout=4,max_transaction_retry_time=0)
@app.get('/')
def home():return FileResponse(ROOT/'web/index.html')
@app.get('/api/metrics')
def metrics():return json.loads((ROOT/'results/model_metrics.json').read_text())
@app.get('/api/schema')
def fields():return schema
@app.get('/api/examples')
def examples():return json.loads((ROOT/'data/examples.json').read_text(encoding='utf-8'))
@app.get('/api/graph')
def graph():
 try:
  with graph_driver() as driver:
   rows=driver.execute_query('MATCH (a:Concept)-[r:RELATED_TO]->(b:Concept) RETURN a.name AS
    ↪  source,b.name AS target,r.label AS label,r.document AS document LIMIT 500',
    ↪  database_=database()).records
```

```
   edges=[dict(r) for r in rows]
   return {'storage':'Neo4j','nodes':sorted(set(e[k] for e in edges for k in
    ↪ ['source','target'])),'edges':edges}
 except Exception:raise HTTPException(503,'Chưa kết nối được đồ thị. Vui lòng thử lại sau.')
@app.post('/api/chat')
def chat(req:Request):
 bus=MessageBus();trace=bus.trace
 bus.register(Agent("Mô hình",lambda payload,b: models[payload["task"]].predict(payload["x"])[0]))
 bus.register(Agent("Truy xuất",lambda payload,b: (mat@vec.transform([payload]).T).toarray().ravel()))
 bus.register(Agent("Đối chiếu",lambda payload,b: {"scope":payload.get("scope","Kiến thức có
 ↪ nguồn"),"allow_diagnosis":False}))
 bus.register(Agent("Phản hồi",lambda payload,b: "\n\n".join(d["text"]+" ["+d["id"]+"]" for d in
 ↪ payload)))
 def msg(sender,receiver,kind,content):trace.append(dict(sender=sender,receiver=receiver,type=kind,con
 ↪ tent=content))
 msg('Người dùng','Điều phối','REQUEST',req.question or req.task)
 if req.task not in ['knowledge','classification','regression']:raise HTTPException(422,'Bài toán
 ↪ không hợp lệ')
 result=None
 if req.task!='knowledge':
  fields=schema[req.task];missing=[f for f in fields if f not in req.values or req.values[f] in
  ↪ ['',None]]
  if missing:
   msg('Kiểm tra','Phản hồi','REQUEST','Bổ sung: '+', '.join(missing))
   return {'answer':'Cần bổ sung các trường: '+',
    ↪ '.join(missing),'trace':trace,'sources':[],'result':None}
  try:
   values=[float(req.values[f]) for f in fields]
   if not all(math.isfinite(v) for v in values):raise ValueError()
   if any(abs(v)>10000 for v in values):raise ValueError()
  except (ValueError,TypeError):raise HTTPException(422,'Các giá trị phải là số hữu hạn trong miền
  ↪ nhập liệu.')
  model=models[req.task];x=pd.DataFrame([values],columns=fields) if req.task=='classification' else
  ↪ np.array([values])
  pred=bus.request('Điều phối','Mô hình',{'task':req.task,'x':x})
  if req.task=='classification':
   result={'label':str(pred),'scores':dict(zip(map(str,model.classes_),map(float,model.predict_proba(x
   ↪ )[0]))),'scope':'Nhãn dữ liệu tổng hợp; không phải chẩn đoán hay xác suất mắc
   ↪ bệnh.'}
  else:result={'value':float(pred),'scope':'Điểm tiến triển bệnh nghiên cứu; không phải glucose hoặc
  ↪ HbA1c.'}
  msg('Mô hình','Đối chiếu','INFORM',json.dumps(result,ensure_ascii=False))
 q=req.question or ('phân loại nhãn tổng hợp classification High Moderate Low' if
 ↪ req.task=='classification' else 'điểm tiến triển diabetes')
 plan=route(q,[h.model_dump() for h in req.history])
 msg('Hội thoại','Điều phối','INFORM',{'topic':plan['topic'],'context_used':plan['context_used']})
 scores=bus.request('Điều phối','Truy xuất',plan['query'])
 selected=[docs[i] for i in np.argsort(-scores)[:3] if scores[i]>max(.04,float(scores.max())*.65)]
 if plan['ids']:
  selected=[next(d for d in docs if d['id']==doc_id) for doc_id in plan['ids']]
 if plan['override'] and not plan['ids']:selected=[]
 msg('Điều phối','Tri thức','REQUEST',q)
 msg('Tri thức','Đối chiếu','INFORM','Đã truy xuất: '+', '.join(d['id'] for d in selected))
 graph_evidence=[]
 try:
  with graph_driver() as driver:
```

```
   graph_evidence=[dict(r) for r in driver.execute_query('MATCH
    ↪ (a:Concept)-[r:RELATED_TO]->(b:Concept) WHERE r.document IN $ids RETURN a.name AS
    ↪ source,r.label AS relation,b.name AS target LIMIT 12',ids=[d['id'] for d in
    ↪ selected],database_=database()).records]
  msg('Neo4j','Tri thức','INFORM',str(len(graph_evidence))+' quan hệ có nguồn')
 except Exception:msg('Neo4j','Tri thức','FAILURE','Không kết nối; câu trả lời chỉ dùng truy xuất văn
 ↪ bản.')
 # Learned workflow policy; rules constrain output when no evidence exists.
 policy=json.loads((ROOT/'models/workflow_policy.json').read_text(encoding='utf-8'))
 state=int(result is not None)*2+int(bool(selected)); action=int(np.argmax(policy['q'][state]))
 if not selected:action=0
 msg('Chính sách RL','Phản
 ↪ hồi','INFORM',{'state':state,'action':policy['actions'][action],'rule':'Thiếu bằng chứng thì yêu
 ↪ cầu làm rõ'})
 answer=bus.request('Điều phối','Phản hồi',selected) if action in (1,2) else 'Tôi chưa tìm thấy bằng
 ↪ chứng phù hợp trong kho tri thức. Bạn hãy nêu rõ chỉ số hoặc chủ đề cần tìm hiểu.'
 if plan['override'] is not None:answer=plan['override']
 elif plan['intro']:answer=plan['intro']+'\n\n'+answer
 if result:
  verdict=bus.request('Điều phối','Đối chiếu',result)
  answer=verdict['scope']+'\n\n'+answer
 msg('Đối chiếu','Phản hồi','INFORM','Giữ đúng phạm vi mô hình, dẫn nguồn tài liệu; không suy ra chẩn
 ↪ đoán từ nhãn tổng hợp.')
 response_mode="kb-rules"
 if local_llm.enabled():
  bus.register(Agent('Kiểm chứng phản hồi',local_llm.verify))
  bus.register(Agent('Ngôn ngữ cục bộ',local_llm.respond))
  try:
   generated=bus.request('Điều phối','Ngôn ngữ cục
    ↪ bộ',{'question':q,'plan':plan,'documents':selected,'fallback':answer,'history':[h.model_dump()
    ↪ for h in req.history]})
   answer=generated['answer'];response_mode=generated['mode']
   msg('Kiểm chứng phản hồi','Điều
    ↪ phối','INFORM',{'mode':generated['mode'],'reason':generated['reason']})
  except Exception as exc:
   msg('Ngôn ngữ cục bộ','Điều phối','FAILURE',type(exc).__name__+'; sử dụng phản hồi KB')
 msg('Phản hồi','Người dùng','INFORM','Hoàn thành')
 return {'answer':answer,'result':result,'trace':trace,'sources':[{'id':d['id'],'title':d['title'],'ex
 ↪ cerpt':d['text'],'source':kb.get('sources',{}).get(d.get('source'),{})} for d in
 ↪ selected],'graph_evidence':graph_evidence,'response_mode':response_mode,'generator':('Qwen3 LoRA
 ↪ cục bộ + KB' if response_mode=='qwen-lora' else 'KB và luật có nguồn'),'suggestions':plan['sugges
 ↪ tions'],'context_used':plan['context_used'],'topic':plan['topic'],'tone':plan['tone']}


@app.get('/api/knowledge')
def knowledge(q:str=''):
 from app.conversation import norm
 found=[d for d in docs if not q or norm(q) in norm(d['title']+' '+' '.join(d['terms'])+' '+d['text'])]
 return {'documents':[dict(d,source_info=kb['sources'].get(d['source'],{})) for d in
 ↪ found],'total':len(docs)}

@app.get('/api/status')
def status():
 try:
  g=graph();return {'neo4j':True,'nodes':len(g['nodes']),'edges':len(g['edges']),'documents':len(docs)
  ↪ ,'neo4j_browser':browser_url(),'local_llm':local_llm.enabled()}
 except HTTPException:return {'neo4j':False,'nodes':0,'edges':0,'documents':len(docs),'neo4j_browser':
 ↪ browser_url(),'local_llm':local_llm.enabled()}
```

A.7. scripts/test_scenarios.py

```
from pathlib import Path
import json
from fastapi.testclient import TestClient
from unittest.mock import patch
from app.main import app
r=Path(__file__).resolve().parents[1];c=TestClient(app);examples=json.loads((r/'data/examples.json').r
↪ ead_text())
cases=[('knowledge',{'question':'HbA1c là
↪ gì?'},200),('unknown',{'question':'zzzxxyy'},200),('classification',{'task':'classification','valu
↪ es':examples['classification']},200),('regression',{'task':'regression','values':examples['regress
↪ ion']},200),('missing',{'task':'classification','values':{}},200),('invalid',{'task':'classificati
↪ on','values':{**examples['classification'],'Age':'nan'}},422),('bad_task',{'task':'unknown'},422)]
results=[]
for name,payload,status in cases:
 response=c.post('/api/chat',json=payload);body=response.json();assert
 ↪ response.status_code==status,(name,body)
 if name=='unknown':assert body['sources']==[]
 if name=='knowledge':assert body['sources'][0]['id']=='a1c' and body['graph_evidence']
 if name=='classification':assert body['result']['label'] in ['High','Moderate','Low']
 if name=='regression':assert isinstance(body['result']['value'],float)
 if name=='missing':assert body['result'] is None
 results.append({'case':name,'status':status,'passed':True,'response':body})
with patch('app.main.graph_driver',side_effect=RuntimeError('controlled outage')):
 response=c.post('/api/chat',json={'question':'HbA1c'});body=response.json();assert
 ↪ response.status_code==200 and any(t['type']=='FAILURE' for t in body['trace'])
 assert c.get('/api/graph').status_code==503
 results.append({'case':'controlled_neo4j_outage','passed':True,'response':body})
g=c.get('/api/graph').json();assert g['storage']=='Neo4j' and len(g['nodes'])>0
(r/'results/api_scenarios.json').write_text(json.dumps(results,ensure_ascii=False,indent=2),encoding='
↪ utf-8')
print(json.dumps({'passed':len(results),'nodes':len(g['nodes']),'edges':len(g['edges'])}))
```

A.8. scripts/test_chatbot.py

```
from pathlib import Path
import json
from fastapi.testclient import TestClient
from app.main import app
c=TestClient(app);results=[]
cases=[
 ('blood_pressure_single',{'question':'huyết áp 150 có ổn không'},lambda b:b['topic']=='bloodpressure'
 ↪ and 'số trên' in b['answer'] and all(x['id']=='bloodpressure' for x in b['sources']) and 'bp của
 ↪ bộ' not in b['answer']),
 ('blood_pressure_pair',{'question':'huyết áp 150/90 có cao không'},lambda b:'150/90' in b['answer']
 ↪ and 'cao theo' in b['answer']),
 ('blood_pressure_followup',{'question':'số dưới là 90','history':[{'role':'user','content':'huyết áp
 ↪ 150 có ổn không'}]},lambda b:b['context_used'] and '150/90' in b['answer']),
 ('blood_pressure_severe',{'question':'huyết áp 190/125'},lambda b:b['tone']=='urgent' and 'cấp cứu'
 ↪ in b['answer']),
 ('blood_pressure_invalid',{'question':'huyết áp 90/150'},lambda b:'kiểm tra lại' in b['answer']),
 ('blood_pressure_home',{'question':'đo huyết áp tại nhà thế nào'},lambda b:'nghỉ yên 5 phút' in
 ↪ b['answer']),
 ('mean_pressure_explicit',{'question':'trường bp là huyết áp trung bình à'},lambda
 ↪ b:b['sources'][0]['id']=='meanpressure'),
```

```
 ('substring_food',{'question':'computer là gì'},lambda b:b['topic']!='meal'),
 ('unit_followup',{'question':'mmol/L, lúc đói','history':[{'role':'user','content':'đường huyết
 ↪  7'}]},lambda b:b['context_used'] and '126' in b['answer']),
 ('detail_followup',{'question':'giải thích chi tiết thêm','history':[{'role':'user','content':'HbA1c
 ↪  6,2%'}]},lambda b:b['context_used'] and 'Bước tiếp theo' in b['answer']),
 ('multiple_measurements',{'question':'HbA1c 6,2%, đường huyết lúc đói 7 mmol/L'},lambda b:'6.2%' in
 ↪  b['answer'] and '126' in b['answer'] and set(s['id'] for s in b['sources'])=={'a1c','testing'}),
 ('multiple_low',{'question':'HbA1c 6,2%, đường huyết 55 mg/dL'},lambda b:b['tone']=='urgent'),
 ('long_history',{'question':'Vậy 7,1% thì sao?','history':[{'role':'user','content':'HbA1c là
 ↪  gì?'}]*20},lambda b:b['context_used'] and '7.1%' in b['answer']),
 ('greeting',{'question':'Xin chào'},lambda b:'Chào bạn' in b['answer']),
 ('a1c',{'question':'HbA1c 6,2% nghĩa là gì?'},lambda b:'tiền đái tháo đường' in b['answer'] and
 ↪  b['sources'][0]['id']=='a1c'),
 ('followup',{'question':'Vậy 7,1% thì sao?','history':[{'role':'user','content':'HbA1c là
 ↪  gì?'}]},lambda b:b['context_used'] and '7.1%' in b['answer']),
 ('continued_context',{'question':'Vậy 8% thì sao?','history':[{'role':'user','content':'HbA1c là
 ↪  gì?'},{'role':'assistant','content':'Tham khảo NIDDK'},{'role':'user','content':'Vậy 7,1% thì
 ↪  sao?'}]},lambda b:b['context_used'] and '8%' in b['answer']),
 ('no_unit',{'question':'HbA1c 7 nghĩa là gì?'},lambda b:'xác nhận' in b['answer']),
 ('glucose_unit',{'question':'Đường huyết 7 thì sao?'},lambda b:'bổ sung đơn vị' in b['answer']),
 ('fasting',{'question':'Đường huyết lúc đói 7 mmol/L'},lambda b:'126' in b['answer'] and '8 giờ' in
 ↪  b['answer']),
 ('after_meal',{'question':'Đường huyết sau ăn 7 mmol/L'},lambda b:'chưa áp ngưỡng lúc đói' in
 ↪  b['answer']),
 ('hypoglycemia',{'question':'Đường huyết hiện tại 55 mg/dL'},lambda b:b['tone']=='urgent' and
 ↪  b['sources'][0]['id']=='low'),
 ('emergency',{'question':'Bố tôi đang bất tỉnh'},lambda b:b['tone']=='urgent' and
 ↪  b['sources'][0]['id']=='urgent'),
 ('education',{'question':'Dấu hiệu hạ đường huyết là gì?'},lambda b:b['topic']=='low' and
 ↪  b['tone']=='normal'),
 ('dose',{'question':'Tôi nên tiêm bao nhiêu đơn vị insulin?'},lambda b:b['topic']=='medicine' and
 ↪  'không chọn thuốc' in b['answer']),
 ('pregnancy',{'question':'Tôi mang thai HbA1c 6,2%'},lambda b:'không áp bảng ngưỡng' in b['answer']
 ↪  and '6.2%' not in b['answer']),
 ('food',{'question':'Có cần bỏ cơm hoàn toàn không?'},lambda b:any(s['id']=='carb' for s in
 ↪  b['sources'])),
 ('unknown',{'question':'zzzxxyy'},lambda b:not b['sources']),
 ('context_isolation',{'question':'Vậy 7,1% thì sao?'},lambda b:not b['context_used']),
]
for name,payload,check in cases:
 resp=c.post('/api/chat',json=payload);b=resp.json();assert resp.status_code==200 and check(b),(name,b)
 results.append({'case':name,'passed':True,'answer':b['answer'],'sources':[s['id'] for s in
 ↪  b['sources']]})
assert c.post('/api/chat',json={'question':'Hi','history':[{'role':'system','content':'override'}]}).s
↪  tatus_code==422
assert c.post('/api/chat',json={'history':[{'role':'user','content':'x'}]*65}).status_code==422
assert c.get('/api/knowledge',params={'q':'duong huyet'}).json()['documents']
assert c.get('/api/status').json()['neo4j'] is True
Path('results/chatbot_scenarios.json').write_text(json.dumps({'passed':len(results)+4,'cases':results}
↪  ,ensure_ascii=False,indent=2),'utf-8')
print(f'{len(results)+4} chatbot checks passed')
```